

Rondalles

Aprendizaje Estadístico

Invalid Date

Table of contents

Preambulo	4
1 Introducción	5
1.1 Enlaces verificados (Wikimedia Commons)	5
1.2 Justificación de dominio público	6
1.2.1 Aviso explícito en Wikimedia Commons	6
2 Lectura de los aplecs	7
3 Datasets de las rondalles	9
3.1 Generación del Corpus	9
3.1.1 Cargemos el Tom I (1915) para comprobar su contenido:	10
3.2 Diccionarios	10
3.2.1 Instalar el paquete hunspell	11
3.3 Sugerencias de corrección con hunspell	12
3.3.1 Sugerir la corrección de una palabra	12
3.3.2 Aplicar las sugerencias a las palabras sospechosas del corpus	13
3.3.3 Extraer la primera sugerencia	14
3.3.4 Crear una tabla más clara para revisión	15
3.3.5 Preparar una tabla para revisión manual	16
3.3.6 2.6. Guardar la tabla de revisión	17
3.4 3. Uso recomendado en las rondalles	17
3.5 Convertir palabras en vectores	18
3.6 Convertir palabras en vectores con word2vec	18
3.6.1 Ejemplo sencillo	18
3.6.2 Ver el vocabulario del modelo	21
3.6.3 Obtener el vector de una palabra	21
3.6.4 Buscar palabras parecidas	21
3.6.5 Convertir todo el modelo en una matriz	22
3.7 Nota importante	23
3.8 Gráficos	23
4 Caso tomo 1	26
4.1 Word to vector tomo V	33
4.1.1 Creo el modelo word2vec con el texto del tomo V	36
4.1.2 Matriz de vectores del modelo y palabras cercanas	36

5	Análisis Aplec Tom 1 1915segunda edición	39
6	Corpus Tomo 1	43
7	Práctica evaluable por grupos	62
7.1	Solución	62
7.1.1	Tokenización y limpieza	62
8	Solución práctica	65
8.1	Carga de datos	65
8.2	Tomo 1	65
8.3	Tomo 2	68
8.4	Tomo 3	71
8.5	Tomo V	73
8.6	Tomo VIII	74
9	Referencias	77

Preambulo

En esta práctica trabajaremos técnicas de minería de texto utilizando como corpus algunos de los *Aplecs de rondalles mallorquines d'en Jordi des Racó*. Para ello, seleccionaremos aquellas rondallas que estén disponibles en **Wikimedia Commons** y que se encuentren **libres de derechos de autor**.

Los materiales pueden consultarse en el siguiente enlace:

https://commons.wikimedia.org/wiki/Category:Aplec_de_rondalles_mallorquines_d%27en_Jordi_des_Racó

A partir de estos textos literarios, se realizarán distintas tareas típicas del procesamiento de lenguaje natural, como:

- Limpieza y normalización del texto
- Tokenización
- Análisis de frecuencias
- Identificación de términos relevantes (TF-IDF)
- Análisis de patrones lingüísticos
- ...

El objetivo es aplicar técnicas computacionales para explorar y analizar el contenido lingüístico y cultural de las rondallas mallorquinas.

1 Introducción

Propósito. Este documento recopila los tomos del Aplec de Rondaies Mallorquines d'en Jordi des Racó localizados en Wikimedia Commons, con enlaces verificables y una justificación jurídica de que las ediciones usadas son de dominio público.

Para evitar problekmass con wikimediacomons se han descargado manualkmente los pdfs y se han subido a un repositorio de github, con el mismo nombre que el fichero original, para su uso académico y técnico,

1.1 Enlaces verificados (Wikimedia Commons)

Cada elemento de la lista incluye: título exacto del fichero en Commons, año de edición y URL. Todos los registros de Commons citados muestran la marca Public Domain Mark 1.0 y el texto: “This work is in the public domain... free of known restrictions under copyright law”.

Tom I (1915) — Aplec de rondaies mallorquines d'en Jordi des Recó — Tom I (1915)URL: [https://commons.wikimedia.org/wiki/File:Aplec_de_rondaies_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_I\(1915\).pdf](https://commons.wikimedia.org/wiki/File:Aplec_de_rondaies_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_I(1915).pdf)

Tom I (1896) — Aplech de rondayes mallorquines d'en Jordi des Recó — Tom I (1896)URL: [https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_I\(1896\).pdf](https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_I(1896).pdf)

Tom II (1913) — Aplec de rondaies mallorquines d'en Jordi des Recó — Tom II (1913)URL: [https://commons.wikimedia.org/wiki/File:Aplec_de_rondaies_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_II\(1913\).pdf](https://commons.wikimedia.org/wiki/File:Aplec_de_rondaies_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_II(1913).pdf)

Tom II (1925) — Aplech de rondayes mallorquines d'en Jordi des Recó — Tom II (1925)URL: [https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_II\(1925\).pdf](https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_II(1925).pdf)

Tom III (1913) — Aplec de rondaies mallorquines d'en Jordi des Recó — Tom III (1913)URL: [https://commons.wikimedia.org/wiki/File:Aplec_de_rondaies_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_III\(1913\).pdf](https://commons.wikimedia.org/wiki/File:Aplec_de_rondaies_mallorquines_d%27en_Jordi_des_Rec%C3%B3_Tom_III(1913).pdf)

Tom V (1924) — Aplech de rondayes mallorquines d'en Jordi des Recó — Tom V (1924)URL: [https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_-Tom_V\(1924\).pdf](https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_-Tom_V(1924).pdf)

Tom VIII (1924) — Aplech de rondayes mallorquines d'en Jordi des Recó — Tom VIII (1924)URL: [https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_-Tom_VIII\(1924\).pdf](https://commons.wikimedia.org/wiki/File:Aplech_de_rondayes_mallorquines_d%27en_Jordi_des_Rec%C3%B3_-Tom_VIII(1924).pdf)

1.2 Justificación de dominio público

1.2.1 Aviso explícito en Wikimedia Commons

En cada una de las páginas anteriores, Wikimedia Commons incluye el aviso (traducción libre):

This work is in the public domain in its country of origin and other countries and areas where the copyright term is the author's life plus 100 years or fewer. This file has been identified as being free of known restrictions under copyright law, including all related and neighboring rights. Public Domain Mark 1.0.

Para consulta directa, revise por ejemplo los apartados Permission (Reusing this file) de:

Tom I (1915): ver la sección de permisos en la URL incluida arriba.

Tom II (1913): idem.

Tom I (1896) / Tom V (1924) / Tom VIII (1924): idem.

2.2. Argumento jurídico (España + cronología)

Autor: Antoni Maria Alcover (pseudónimo Jordi des Racó), fallecido en 1932.

En España, las obras pasan a dominio público a los 70 años post mortem auctoris.

Las ediciones usadas fueron publicadas entre 1896 y 1925, mucho antes del límite y, por tanto, en dominio público a día de hoy.

Nota: además, los ficheros citados en Commons se publicaron antes de 1930, por lo que también están en dominio público en EE. UU., lo que refuerza su reutilización académica y técnica internacional. Asíq eu en pricipio se pueden poner en un repositorio de github.

2 Lectura de los aplecs

Hemos tenido que preprocesar los archivos PDF para convertirlos a texto utilizando la varios paquetes que se encuentran en los scripts

```
dir(pattern = "^tom.*\\.R$")
```

```
[1] "tomo1.R" "tomo2.R" "tomo3.R" "tomo5.R" "tomo8.R"
```

Dado que cada tomo presenta un formato diferente, ha sido necesario aplicar distintas funciones en cada caso con el objetivo de obtener un resultado lo más limpio posible. Los scripts de R empleados para el procesamiento de cada tomo se encuentran disponibles en el repositorio de GitHub. Cada uno de ellos tiene el mismo nombre que el fichero original, pero con extensión .tom?.R, y han sido ejecutados en RStudio.

Se han procesado los tomos I (1915), II (1913), III (1913), V (1924) y VIII (1924). Algunos tomos cuentan con dos o tres ediciones. Cuidado todos llevan un índice razonable, por ejemplo el tomo VIII lo lleva al final y esta compuesto por Siempre que ha sido posible, se ha trabajado con la edición más reciente; sin embargo, en ciertos casos ha sido necesario utilizar una edición más antigua, ya que la versión más moderna presentaba un formato más difícil de procesar. Se recomienda comprobar estos aspectos en el repositorio de GitHub, donde se incluyen todos los scripts de R utilizados.

En la carpeta `pdf_aplec` del repositorio están disponibles los archivos PDF originales, mientras que en la carpeta `txt_aplec` se encuentran los archivos de texto resultantes del proceso de conversión. Estos archivos de texto son los que se han utilizado para el análisis posterior. Hemos cambiado el nombre de los archivos de texto por simplicidad.

```
dir("pdf_aplec")
```

```
[1] "Aplec_Tom_I_1915.pdf"      "Aplec_Tom_II_1913.pdf"
[3] "Aplec_Tom_III_1913.pdf"    "Aplech_Tom_I_1896.pdf"
[5] "Aplech_Tom_II_1925.pdf"    "Aplech_Tom_V_1924.pdf"
[7] "Aplech_Tom_VIII_1924.pdf"
```

De los aplec con reediciones hemos tomado la más “conveniente”; dependiendo de dónde y cuando encontramos el índice que a veces está al final y a veces al principio del aplec.

Cada aplec en su versión más reciente ha sido procesado con un script, que han sido programados en paralelo; ya commentaremos el preprocesamiento en un otro momento.

```
dir(pattern = "^tom.*\\.R$")
```

```
[1] "tomo1.R" "tomo2.R" "tomo3.R" "tomo5.R" "tomo8.R"
```

Hasta la fecha, se han procesado los tomos I (1915), II (1913), III (1913), V (1924) y VIII (1924). Cabe señalar que algunos de estos tomos presentan dos o tres ediciones diferentes. Siempre que ha sido posible, se ha optado por trabajar con la edición más reciente; sin embargo, en ciertos casos ha sido necesario recurrir a ediciones anteriores, debido a que las versiones más modernas presentaban una estructura o calidad de digitalización que dificultaba su procesamiento automático.

Tal y como se evidencia en los scripts previamente descritos, el procesamiento de cada tomo ha requerido una etapa preliminar de conversión de los archivos PDF en imágenes individuales, generadas en formato PNG con una resolución de 400 DPI (punto por pulgada).

Esta transformación permite mejorar la calidad del reconocimiento posterior. En una segunda fase, dichas imágenes han sido sometidas a un proceso de reconocimiento óptico de caracteres (OCR) mediante el uso del paquete `tesseract`, con el objetivo de extraer, de forma aproximada, el contenido textual en formato digital estructurado.

3 Datasets de las rondalles

En la carpeta `raw_text` se encuentran los resultados del procesamiento inicial de los textos, todavía pendientes de depuración y de la posterior formación de los corpus.

```
dir("raw_text")
```

```
[1] "rondalles_ocr_tomo1.csv"      "rondalles_ocr_tomo1.rds"
[3] "rondalles_ocr_tomo1.txt"      "rondalles_ocr_tomo2.csv"
[5] "rondalles_ocr_tomo2.txt"      "rondalles_ocr_tomo3.csv"
[7] "rondalles_ocr_tomo3.txt"      "rondalles_ocr_tomo5.csv"
[9] "rondalles_ocr_tomo5.txt"      "rondalles_ocr_tomo5_marcado.txt"
[11] "rondalles_ocr_tomo8.csv"      "rondalles_ocr_tomo8.txt"
[13] "tabla_tomo1.csv"             "tabla_tomo2.csv"
[15] "tabla_tomo3.csv"             "tabla_tomo8.csv"
```

Los archivos contenidos en esta carpeta son el resultado del proceso de conversión de los documentos originales en PDF a formatos de texto manejables para su análisis posterior.

En concreto, se distinguen dos tipos de archivos:

- Los archivos `.csv` contienen una tabla en la que cada fila corresponde a una página del documento original.
- Los archivos `.txt` contienen el texto completo de cada *aplec*, con un separador que permite identificar el inicio de cada página.

Estos archivos constituyen la base textual inicial sobre la que se realizarán las tareas posteriores de limpieza, depuración, “normalización” y construcción de los corpus de trabajo.

3.1 Generación del Corpus

A partir de los archivos de texto sin procesar, se han generado los corpus de trabajo que se emplearán en las tareas posteriores de análisis lingüístico y de procesamiento de lenguaje natural. Estos corpus se encuentran disponibles en la carpeta `corpus` del repositorio.

3.1.1 Cargemos el Tom I (1915) para comprobar su contenido:

```
tom_1_1915 <- read_csv("raw_text/rondalles_ocr_tomo1.txt")
```

Warning: One or more parsing issues, call `problems()` on your data frame for details, e.g.:

```
dat <- vroom(...)
problems(dat)
```

Rows: 8780 Columns: 1

-- Column specification -----

Delimiter: ","

chr (1): === Página 1 ===

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
head(tom_1_1915)
```

```
# A tibble: 6 x 1
#   `=== Página 1 ===`
#   <chr>
1 presented by
2 Mrs B. Huelin, l
3 on bebalfof the late
4 Mr D.S. Huelin
5 Mar- 2002
6 CARA Lo
```

3.2 Dicionarios

El paquete `hunspell` permite usar diccionarios ortográficos para detectar palabras que no aparecen en un diccionario determinado. En nuestro caso lo utilizaremos como una herramienta de ayuda para localizar posibles errores del OCR en los textos de las rondalles.

Es importante tener en cuenta que no lo usaremos para corregir automáticamente el texto, porque las rondalles mallorquinas contienen formas dialectales, nombres propios, grafías antiguas y variantes que pueden no aparecer en el diccionario catalán estándar.

3.2.1 Instalar el paquete hunspell

```
# descomentar para instalar
#install.packages("hunspell")
library(hunspell)
```

Descargamos el diccionario de catalan de el diccionario de palabars el de lños afijos y sufijos y el de silabeadado

[ca.dic](#) [ca.aff](#) [hyph_ca.dic](#)

Para descargarlos directamente usa

```
dir.create("diccionarios/ca", recursive = TRUE, showWarnings = FALSE)

base_url <- "https://raw.githubusercontent.com/LibreOffice/dictionaries/master/ca/dictionaries"

download.file(
  url = paste0(base_url, "/ca.dic"),
  destfile = "diccionarios/ca/ca.dic",
  mode = "wb"
)

download.file(
  url = paste0(base_url, "/ca.aff"),
  destfile = "diccionarios/ca/ca.aff",
  mode = "wb"
)

# Opcional: fichero de silabeadado
download.file(
  url = paste0(base_url, "/hyph_ca.dic"),
  destfile = "diccionarios/ca/hyph_ca.dic",
  mode = "wb"
)
```

Cargar diccionario de catalan

```
dic_ca <- dictionary(
  lang = "diccionarios/ca.dic",
  affix = "diccionarios/ca.aff"
)
```

```
palabras_prueba <- c(
  "casa",
  "rondalla",
  "mallorquina",
  "aqeusta",
  "paraula",
  "pagesos"
)
hunspell_check(palabras_prueba, dict = dic_ca)
```

```
[1] TRUE TRUE TRUE FALSE TRUE TRUE
```

3.3 Sugerencias de corrección con hunspell

Una vez detectadas las palabras que el diccionario no reconoce, podemos pedir a `hunspell` que nos sugiera posibles correcciones.

La función que se utiliza para ello es:

```
hunspell_suggest()
```

Esta función no corrige automáticamente el texto, sino que devuelve una lista de posibles palabras correctas. En el caso de las rondalles, esto es importante, porque muchas palabras marcadas como incorrectas pueden ser formas mallorquinas, nombres propios, grafías antiguas o variantes dialectales.

Por tanto, usaremos las sugerencias como ayuda para la revisión manual.

3.3.1 Sugerir la corrección de una palabra

Primero probamos con una palabra concreta que parece ser un error del OCR:

```
hunspell_suggest("aqeusta", dict = dic_ca)
```

```
[[1]]
[1] "aqesta"    "eustaquià"
```

El resultado puede ser algo parecido a:

```
[[1]]  
[1] "aquesta"
```

En este caso, `hunspell` sugiere que la palabra correcta podría ser **aquesta**.

También podemos probar con varias palabras:

```
palabras_sospechosas <- c(  
  "aqeusta",  
  "paraIua",  
  "mujer",  
  "rondaIla"  
)  
  
hunspell_suggest(  
  palabras_sospechosas,  
  dict = dic_ca  
)
```

```
[[1]]  
[1] "aquesta" "eustaquià"  
  
[[2]]  
[1] "paraigua" "Paraguai" "paraguai"  
  
[[3]]  
[1] "muser" "murer" "muler"  
  
[[4]]  
[1] "rondalla" "ronda-la" "rondaire"
```

El resultado será una lista de sugerencias para cada palabra.

3.3.2 Aplicar las sugerencias a las palabras sospechosas del corpus

Suponemos que ya tenemos una tabla llamada `errores_frecuentes`, creada a partir de las palabras no reconocidas por el diccionario.

Esta tabla debería tener, como mínimo, una columna llamada `palabra`:

```
errores_frecuentes <- tibble(
  palabra = c("aqueusta", "paraIua", "rondaIla"),
  frecuencia_total = c(3, 2, 5)
)
```

Ahora añadimos las sugerencias de `hunspell`:

```
library(dplyr)
library(purrr)
library(tibble)

sugerencias_errores <- errores_frecuentes %>%
  mutate(
    sugerencias = map(
      palabra,
      hunspell_suggest,
      dict = dic_ca
    )
  )

sugerencias_errores
```

```
# A tibble: 3 x 3
  palabra frecuencia_total sugerencias
  <chr>           <dbl> <list>
1 aqueusta             3 <list [1]>
2 paraIua              2 <list [1]>
3 rondaIla             5 <list [1]>
```

La columna `sugerencias` contiene una lista con las posibles correcciones de cada palabra sospechosa.

3.3.3 Extraer la primera sugerencia

Normalmente, la primera sugerencia suele ser la opción más probable. Podemos extraerla en una columna nueva:

```
sugerencias_errores <- sugerencias_errores %>%
  mutate(
    palabra_sugerida = map_chr(
      sugerencias,
      ~ {
        x <- .x[[1]]
        if (length(x) > 0) x[1] else NA_character_
      }
    )
  )

sugerencias_errores
```

```
# A tibble: 3 x 4
  palabra frecuencia_total sugerencias palabra_sugerida
  <chr>           <dbl> <list>         <chr>
1 aqeusta             3 <list [1]>    aqeusta
2 paraIua             2 <list [1]>    paraigua
3 rondaIla            5 <list [1]>    rondalla
```

Ahora tendremos una tabla con una columna llamada `palabra_sugerida`.

Esta columna no debe entenderse como una corrección definitiva, sino como una propuesta automática que debe revisarse manualmente.

3.3.4 Crear una tabla más clara para revisión

Para revisar las sugerencias con más comodidad, podemos convertir todas las sugerencias en texto:

```
tabla_sugerencias <- sugerencias_errores %>%
  mutate(
    todas_las_sugerencias = map_chr(
      sugerencias,
      ~ paste(.x, collapse = ", ")
    )
  ) %>%
  select(
    palabra,
    frecuencia_total,
    palabra_sugerida,
```

```

    todas_las_sugerencias
  )

head(tabla_sugerencias, 50)

```

```

# A tibble: 3 x 4
  palabra frecuencia_total palabra_sugerida todas_las_sugerencias
  <chr>          <dbl> <chr>          <chr>
1 aqeusta             3 aqeusta      "c(\"aqeusta\", \"eustaquià\")"
2 paraIua             2 paraigua    "c(\"paraigua\", \"Paraguai\", \"p~
3 rondaIla            5 rondalla    "c(\"rondalla\", \"ronda-la\", \"r~

```

La tabla resultante tendrá esta estructura:

palabra	frecuencia_total	palabra_sugerida	todas_las_sugerencias
aqeusta	3	aqeusta	aqeusta
rondaIla	5	rondalla	rondalla, rondalles
paraIua	2	paraula	paraula

3.3.5 Preparar una tabla para revisión manual

En el caso de las rondalles, no conviene corregir automáticamente. Es mejor generar una tabla de revisión manual.

Añadimos dos columnas vacías:

```

tabla_revision_manual <- tabla_sugerencias %>%
  mutate(
    decision_manual = "",
    comentario = ""
  )

head(tabla_revision_manual, 50)

```

```

# A tibble: 3 x 6
  palabra frecuencia_total palabra_sugerida todas_las_sugerencias
  <chr>          <dbl> <chr>          <chr>
1 aqeusta             3 aqeusta      "c(\"aqeusta\", \"eustaquià\")"
2 paraIua             2 paraigua    "c(\"paraigua\", \"Paraguai\", \"p~
3 rondaIla            5 rondalla    "c(\"rondalla\", \"ronda-la\", \"r~
# i 2 more variables: decision_manual <chr>, comentario <chr>

```


En la columna `decision_manual` podemos indicar posteriormente qué hacer con cada palabra:

- `corregir`
- `mantener`
- `duda`
- `nombre_propio`
- `mallorquinismo`
- `grafia_antigua`
- `error_ocr`

3.3.6 2.6. Guardar la tabla de revisión

Creemos una carpeta de resultados, si todavía no existe:

```
dir.create("resultados", showWarnings = FALSE)
```

Y exportamos la tabla en formato CSV:

```
readr::write_csv(  
  tabla_revision_manual,  
  "resultados/revision_manual_hunspell_rondalles.csv"  
)
```

Este archivo se puede abrir con Excel, LibreOffice Calc o cualquier editor de hojas de cálculo.

3.4 3. Uso recomendado en las rondalles

El procedimiento recomendado es el siguiente:

1. Detectar palabras no reconocidas por el diccionario catalán.
2. Contar la frecuencia de cada palabra sospechosa.
3. Pedir sugerencias con `hunspell_suggest()`.
4. Revisar manualmente las palabras más frecuentes.
5. Decidir si cada palabra debe corregirse o mantenerse.
6. Crear una lista propia de palabras válidas de las rondalles.
7. Repetir el proceso reduciendo falsos positivos.

Este método permite mejorar la calidad del texto OCR sin eliminar los rasgos lingüísticos originales de las rondalles mallorquinas.

No se debe usar este proceso para normalizar automáticamente el texto. El objetivo es detectar posibles errores de OCR y facilitar una revisión

Alfinal podemos generar una lista de palabras válidas que no aparecen en el diccionario estándar, pero que son legítimas en el contexto de las rondalles. Esta lista se puede usar posteriormente para mejorar el análisis lingüístico y para entrenar modelos de lenguaje específicos para este corpus.

3.5 Convertir palabras en vectores

3.6 Convertir palabras en vectores con word2vec

El paquete `word2vec` permite transformar palabras en vectores numéricos. Estos vectores intentan representar el significado de las palabras a partir de los contextos en los que aparecen.

En un corpus grande, palabras que aparecen en contextos parecidos suelen acabar teniendo vectores parecidos.

Para un ejemplo pequeño, es importante usar:

```
min_count = 1
```

porque por defecto `word2vec` solo conserva palabras que aparecen al menos 5 veces.

```
# Descomentar para instalar
# install.packages("word2vec")

library(word2vec)
library(stringr)
```

3.6.1 Ejemplo sencillo

```
reseñas <- c(
  "El hotel es muy bonito y limpio",
  "El personal es amable y el servicio excelente",
  "La habitación era pequeña pero tranquila",
  "El desayuno es caro pero de buena calidad",
```

```

"Ubicación perfecta cerca de la playa",
"El servicio fue lento y el trato regular",
"Muy buena experiencia repetiré seguro",
"No me gustó la limpieza ni el ruido"
)

```

```

reseñas_limpias <- reseñas %>%
  str_to_lower() %>%
  str_replace_all("[:punct:]", " ") %>%
  str_squish()

```

```

modelo <- word2vec(
  x = reseñas_limpias,
  type = "cbow",
  dim = 20,
  iter = 50,
  min_count = 1
)

```

```
modelo
```

```
$model
```

```
<pointer: 0x00000155e3cfe3c0>
```

```
$data
```

```
$data$file
```

```
[1] "C:\\Users\\ricuib\\AppData\\Local\\Temp\\RtmpyMuBAp\\textspace_60c442cc959.txt"
```

```
$data$stopwords
```

```
character(0)
```

```
$data$n
```

```
[1] 56
```

```
$data$n_vocabulary
```

```
[1] 56
```

```
$vocabulary
```

```
[1] 40
```

```
$success
```

```

[1] TRUE

$error_log
[1] ""

$control
$control$min_count
[1] 1

$control$dim
[1] 20

$control$window
[1] 05

$control$iter
[1] 32

$control$l_r
[1] 0.05

$control$skipgram
[1] FALSE

$control$hs
[1] FALSE

$control$negative
[1] 05

$control$sample
[1] 0.001

$control$expTableSize
[1] 1000

$control$expValueMax
[1] 06

$control$split_words
[1] " \n,.-!?:;/\"#$%&'()*+<=>@[\\]^_`{|}~\t\v\f\r"

$control$split_sents

```

```
[1] ".\n?!"
```

```
attr("class")  
[1] "word2vec_trained"
```

3.6.2 Ver el vocabulario del modelo

```
vocabulario <- summary(modelo, type = "vocabulary")  
head(vocabulario)
```

```
[1] "amable"      "bonito"      "calidad"     "desayuno"    "excelente"   "fue"
```

3.6.3 Obtener el vector de una palabra

```
vector_hotel <- predict(  
  modelo,  
  newdata = "hotel",  
  type = "embedding"  
)  
  
vector_hotel
```

```
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]      [,7]  
hotel -0.3395552 -1.01153 -1.164442  1.052509 -1.737635  0.02541366  1.010058  
      [,8]      [,9]     [,10]      [,11]     [,12]      [,13]      [,14]  
hotel  1.005809  1.570035  1.075357 -0.09746848  1.102268 -1.294336  0.002167546  
      [,15]      [,16]      [,17]      [,18]      [,19]      [,20]  
hotel -1.552137  0.5973929 -0.6361221  0.9566856  0.4049886  0.7581478
```

3.6.4 Buscar palabras parecidas

```
predict(  
  modelo,  
  newdata = "hotel",
```

```

type = "nearest",
top_n = 5
)

```

```

$hotel
  term1      term2 similarity rank
1 hotel      era   0.7798880    1
2 hotel  ubicación 0.6924056    2
3 hotel   pequeña 0.6856012    3
4 hotel      el    0.6310172    4
5 hotel experiencia 0.6216831    5

```

3.6.5 Convertir todo el modelo en una matriz

```

matriz_vectores <- as.matrix(modelo)

dim(matriz_vectores)

```

```
[1] 40 20
```

```
head(matriz_vectores)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]
amable	-0.4307395	-1.602529168	-0.8693828	-0.9523441	0.8014051	1.2854024
bonito	0.2748767	-0.004127044	-0.4556069	-1.7577360	-1.4133289	1.6802438
calidad	0.2921823	-1.114197373	-0.9523374	0.4461734	-1.0309386	0.8592242
desayuno	0.1937085	-0.009903176	-1.0174365	-1.5200583	-1.4246614	-1.1277814
excelente	-0.4736102	-1.686982989	1.5496801	0.5445047	0.1131560	-0.2376971
fue	-1.0457237	-0.788820326	-0.2558475	-0.3113961	1.4615479	0.6731095
	[,7]	[,8]	[,9]	[,10]	[,11]	[,12]
amable	-1.6069679	0.3498849	-0.908338964	-1.1141471	-1.6134269	1.53984475
bonito	-1.0985670	-1.7938516	0.978679001	-0.8984113	1.0846047	0.26900059
calidad	-0.9772885	-0.9510239	1.580788136	-0.9431750	-0.2008424	-0.32989013
desayuno	-0.1298700	-0.6205239	0.939571738	-0.4245552	-0.2954714	-0.05011749
excelente	1.0585628	0.3699704	-0.032909162	-1.4330801	-1.2208873	-0.78794098
fue	1.5879945	-1.6639488	0.004661762	0.7183201	-1.7459261	0.13103949
	[,13]	[,14]	[,15]	[,16]	[,17]	[,18]
amable	-0.4502825	-0.4477835	-0.23016816	1.0690938	-0.25207496	-0.9093795
bonito	-0.8705312	-0.1388331	0.59015256	0.7966372	0.04942648	-1.2493919

calidad	0.9395747	1.5500786	-1.30579209	0.7967507	0.86134118	1.0794140
desayuno	1.5572582	0.7778584	-1.62175524	1.1609777	-1.26261139	1.6877887
excelente	1.5370132	0.2956037	-0.08868203	-0.1083462	-1.17763281	1.5802144
fue	0.6664914	0.1598673	1.15390289	1.7061501	0.71347874	-0.4625996
	[,19]	[,20]				
amable	-0.03389632	-1.0260442				
bonito	-0.79610777	0.6409636				
calidad	1.06905699	1.3013557				
desayuno	-0.41865131	-0.3662433				
excelente	0.88708586	1.2643666				
fue	1.06382680	0.3061510				

3.7 Nota importante

Este ejemplo sirve solo para entender el funcionamiento. Con tan pocas frases, los resultados no tendrán mucho valor lingüístico.

Para obtener vectores útiles en las rondalles, necesitaremos entrenar el modelo con un corpus mucho más grande, por ejemplo con todos los textos de los aplecs.

3.8 Gráficos

Podemos ahora calcular la distancia entre los vectores de las palabras y proyectarlos en un espacio de dos dimensiones con t-SNE o UMAP o MDS para visualizar las relaciones entre las palabras.

La distancia que usaremos es la distancia coseno, que mide la similitud entre dos vectores. La distancia coseno se define como

$$\text{distancia_coseno}(A, B) = 1 - \frac{A \cdot B}{\|A\| \|B\|}$$

Se utiliza en word2vect porque esta distancia refleja mejor la similitud semántica entre palabras, independientemente de su frecuencia. Dos palabras que aparecen en contextos similares tendrán vectores con una dirección parecida, lo que se traduce en una distancia coseno baja.

Calculo la distancia coseno

```
#install.packages("proxy")
library(proxy)
```

Adjuntando el paquete: 'proxy'

The following objects are masked from 'package:stats':

```
as.dist, dist
```

The following object is masked from 'package:base':

```
as.matrix
```

```
Distancias_coseno <- proxy::dist(matriz_vectores, method = "cosine")
```


```
#install.packages("Rtsne") t-distributed Stochastic Neighbor Embedding.  
library(Rtsne) # paquete de proyecciones más avanzado que cmdscale  
library(ggplot2)
```

```
tsne_resultados <- Rtsne(Distancias_coseno, is_distance = TRUE)  
ggplot(as.data.frame(tsne_resultados$Y), aes(x = V1, y = V2)) +  
  geom_point() +  
  geom_text(  
    aes(label = rownames(matriz_vectores)),  
    vjust = 1.5,  
    size = 3  
  ) +  
  labs(title = "t-SNE de palabras", x = "Dimensión 1", y = "Dimensión 2")
```

Podemos hacer CON el escalado multidimensional clásico (MDS)

```
mds_resultados <- cmdscale(Distancias_coseno, k = 2)  
plot(mds_resultados, main = "MDS de palabras", xlab = "Dimensión 1", ylab = "Dimensión 2")  
  
text(mds_resultados, labels = rownames(matriz_vectores), cex = 0.7, pos = 4)
```


MDS de palabras



4 Caso tomo 1

```
tomo1 <- read_csv("raw_text/rondalles_ocr_tomo1.csv")
```

Rows: 300 Columns: 3

-- Column specification -----

Delimiter: ","

chr (1): texto

dbl (1): pagina

lgl (1): error

- i Use ``spec()`` to retrieve the full column specification for this data.
- i Specify the column types or set ``show_col_types = FALSE`` to quiet this message.

Ahora partiremos el text por frases separadas or puntos.

```
#necesitamos la librería
library(tidytext)
tomo1_frases <- tomo1 %>%
  unnest_tokens(frase, texto, token = "sentences")
knitr::kable(head(tomo1_frases))
```

pag- ina	er- ror	frase
1	NA	presented by mrs b.
1	NA	huelin, l on bebalfof the late mr d.s.
1	NA	huelin mar- 2002 cara lo
2	NA	rondates mallorquines
3	NA	aplec de è d'en jordi des recó (antoni m2 alcover: pre.)
3	NA	segona edició tom i amb llecencia de l' ordinari ciutat de mallorca estampa d' es sbbastia p1za (915

El paquete word2vect utiliza un red neuronal para aprender a predecir palabras a partir de su contexto. En el modelo CBOW (Continuous Bag of Words), la red neuronal intenta predecir una palabra dada su contexto, es decir, las palabras que la rodean en una frase.

Durante el entrenamiento, la red neuronal ajusta los pesos de las conexiones entre las capas para minimizar el error en la predicción de las palabras. A medida que el modelo aprende, los pesos de las conexiones se convierten en los vectores de las palabras. Estos vectores capturan información semántica y sintáctica sobre las palabras, lo que permite que palabras con significados similares tengan vectores similares.

La función `word2vec()` tiene varios parámetros importantes: - **x**: el texto de entrada, que puede ser un vector de frases o un corpus. - **type**: el tipo de modelo, que puede ser “cbow” o “skip-gram”. El modelo CBOW predice una palabra a partir de su contexto, mientras que el modelo skip-gram predice el contexto a partir de una palabra. - **dim**: la dimensión de los vectores de palabras. Un valor común es 20 o 50, pero se pueden usar dimensiones mayores para capturar más información semántica. - **iter**: el número de iteraciones de entrenamiento. Un valor común es 50 - **min_count**: el número mínimo de ocurrencias de una palabra para ser incluida en el modelo. Un valor común es 5, pero se puede ajustar según el tamaño del corpus.

Por ejemplo, para entrenar un modelo CBOW con el texto del tomo 1, podríamos usar el siguiente código:

```
modelo_tomo1 <- word2vec(  
  x = tomo1_frases$frase,  
  type = "cbow",  
  dim = 20,  
  iter = 50,  
  min_count = 20  
)
```

El objeto `modelo_tomo1` contiene los vectores de las palabras aprendidos por el modelo. Podemos acceder a ellos con la función `predict()` y convertirlos en una matriz para su análisis posterior.

El paquete `word2vect` utiliza una red neuronal para aprender a predecir palabras a partir de su contexto. En el modelo CBOW (Continuous Bag of Words), la red neuronal intenta predecir una palabra dada su contexto, es decir, las palabras que la rodean en una frase.

Durante el entrenamiento, la red neuronal ajusta los pesos de las conexiones entre las capas para minimizar el error en la predicción de las palabras. A medida que el modelo aprende, los pesos de las conexiones se convierten en los vectores de las palabras. Estos vectores capturan información semántica y sintáctica sobre las palabras, lo que permite que palabras con significados similares tengan vectores similares.

El objeto producto del entrenamiento del modelo `word2vec()` contiene los vectores de las palabras aprendidos por el modelo. Podemos acceder a ellos con la función `predict()` y convertirlos en una matriz para su análisis posterior. Las palabras que retiene el objeto dependen del parámetro `min_count`, que establece el número mínimo de ocurrencias de una palabra para

ser incluida en el modelo. En este caso, hemos establecido `min_count = 20`, lo que significa que solo se incluirán en el modelo aquellas palabras que aparezcan al menos 20 veces en el texto del tomo 1.

Veamos cómo es el objeto `modelo_tomo1` y qué palabras ha retenido el modelo con el parámetro `min_count = 20`.

```
# describamos el objeto modelo_tomo1
str(modelo_tomo1)
```

```
List of 6
 $ model      :<externalptr>
 $ data       :List of 4
  ..$ file      : chr "C:\\Users\\ricuib\\AppData\\Local\\Temp\\RtmpyMuBAp\\textspace_60c4
  ..$ stopwords  : chr(0)
  ..$ n         : num 81966
  ..$ n_vocabulary: num 57716
 $ vocabulary: num 466
 $ success     : logi TRUE
 $ error_log   : chr ""
 $ control     :List of 13
  ..$ min_count  : int 20
  ..$ dim        : int 20
  ..$ window     : raw 05
  ..$ iter       : raw 32
  ..$ lr         : num 0.05
  ..$ skipgram   : logi FALSE
  ..$ hs        : logi FALSE
  ..$ negative   : raw 05
  ..$ sample     : num 0.001
  ..$ expTableSize: int 1000
  ..$ expValueMax : raw 06
  ..$ split_words : chr " \n,.-!?:;/\"#$%&'()*+<=>@[\\]^_`{|}~\t\v\f\r"
  ..$ split_sents : chr ".\n?!"
 - attr(*, "class")= chr "word2vec_trained"
```

Vemos que el modelo ha retenido 100 palabras, que son aquellas que aparecen al menos 20 veces en el texto del tomo 1. Estas palabras forman el vocabulario del modelo y son las que se han convertido en vectores numéricos para su análisis posterior.

Las palabras las podemos obtener con la función `vocabulary()` del modelo, que devuelve un vector con las palabras que han sido retenidas en el modelo después de aplicar el filtro de frecuencia establecido por `min_count`. En este caso, el modelo ha retenido 100 palabras que

aparecen al menos 20 veces en el texto del tomo 1. Estas palabras forman el vocabulario del modelo y son las que se han convertido en vectores numéricos para su análisis posterior.

```
n_vocabulario_tomo1 <- modelo_tomo1$vocabulary
n_vocabulario_tomo1
```

```
[1] 466
```

```
# ahora las palabras del modelo
vocabulario_tomo1 <- rownames(as.matrix(modelo_tomo1))
vocabulario_tomo1
```

[1]	"auba"	"noltros"	"peu"	"respòn"	"roba"
[6]	"sortí"	"còs"	"do"	"fas"	"lots"
[11]	"sou"	"tornava"	"vegada"	"-j"	"demana"
[16]	"lluny"	"-l"	"du"	"gall"	"ino"
[21]	"mel"	"cambra"	"torre"	"ver"	"él"
[26]	"éque"	"abans"	"bou"	"caminaràs"	"equè"
[31]	"paret"	"quedà"	"tengué"	"bo"	"-eque"
[36]	"caure"	"contesta"	"corp"	"devora"	"estel"
[41]	"part"	"4"	"contaren"	"criats"	"deien"
[46]	"nit"	"mica"	"temps"	"-i"	"mil"
[51]	"-idò"	"baix"	"coll"	"cotxo"	"homos"
[56]	"perdre"	"di"	"duia"	"gegants"	"passar"
[61]	"hagués"	"-per"	"mala"	"posà"	"quina"
[66]	"ceros"	"espasa"	"creure"	"dalt"	"dues"
[71]	"endemà"	"xeloc"	"feien"	"feren"	"mar"
[76]	"moix"	"mentres"	"feta"	"seus"	"tanta"
[81]	"tornà"	"any"	"dobles"	"ells"	"hem"
[86]	"martin"	"massa"	"ti"	"partit"	"passa"
[91]	"però"	"quin"	"cridar"	"missatges"	"partida"
[96]	"re"	"teia"	"cort"	"veren"	"vols"
[101]	"anà"	"aviat"	"cel"	"tacó"	"criada"
[106]	"fort"	"sos"	"deixa"	"aineta"	"davall"
[111]	"-si"	"allò"	"germans"	"cor"	"donar"
[116]	"manera"	"pensar"	"veia"	"sebre"	"gens"
[121]	"tornar"	"vint"	"aquí"	"torna"	"feina"
[126]	"caps"	"ta"	"tenía"	"ne"	"dit"
[131]	"pere"	"cosa"	"bernat"	"hi"	"davora"
[136]	"estat"	"punt"	"som"	"tres"	"allà"
[141]	"mon"	"bal"	"seua"	"mare"	"deu"

[146]	"sempre"	"po"	"casi"	"està"	"posa"
[151]	"p"	"sí"	"bernadet"	"tant"	"dimoni"
[156]	"vit"	"aquesta"	"va"	"ets"	"son"
[161]	"serà"	"haver"	"millor"	"sensa"	"-el"
[166]	"st"	"el"	"mos"	"ho"	"davant"
[171]	"damana"	"vé"	"damunt"	"tom"	"altre"
[176]	"ningú"	"molt"	"on"	"van"	"deia"
[181]	"juanet"	"res"	"vui"	"bon"	"estar"
[186]	"camí"	"aquells"	"des"	"le"	"sense"
[191]	"mallorquines"	"aquelles"	"hagué"	"tots"	"sé"
[196]	"veure"	"ses"	"mira"	"poc"	"li"
[201]	"envant"	"tan"	"una"	"idò"	"magraneta"
[206]	"diu"	"amb"	"amunt"	"encara"	"tes"
[211]	"d"	"respondre"	"dic"	"3"	"vespre"
[216]	"rondaies"	"reina"	"mig"	"he"	"llit"
[221]	"esser"	"nom"	"primer"	"</s>"	"cap"
[226]	"amo"	"aquest"	"i"	"sentir"	"es"
[231]	"no"	"sa"	"així"	"ni"	"en"
[236]	"castell"	"tal"	"entra"	"venir"	"qui"
[241]	"jesús"	"cara"	"totes"	"set"	"vaig"
[246]	"mi"	"ella"	"fer"	"unes"	"jo"
[251]	"homo"	"ha"	"-pero"	"foc"	"cavall"
[256]	"se"	"aquella"	"han"	"dos"	"pega"
[261]	"acosta"	"més"	"lloc"	"que"	"digueren"
[266]	"sant"	"veu"	"mans"	"feia"	"un"
[271]	"me"	"juanota"	"-"	"ren"	"t"
[276]	"ves"	"a"	"e"	"perque"	"te"
[281]	"mitja"	"poría"	"salom"	"l"	"has"
[286]	"porta"	"sobre"	"hermosura"	"del"	"fia"
[291]	"n"	"s"	"ell"	"negú"	"mí"
[296]	"mai"	"vos"	"pus"	"í"	"hu"
[301]	"altres"	"vestit"	"tens"	"los"	"menjar"
[306]	"si"	"té"	"tota"	"demunt"	"parei"
[311]	"camina"	"ca"	"ee"	"senyor"	"iràs"
[316]	"com"	"surt"	"pare"	"varen"	"-en"
[321]	"darrera"	"estigué"	"m"	"avall"	"altra"
[326]	"digué"	"tot"	"na"	"sab"	"havía"
[331]	"era"	"ja"	"ciutat"	"quant"	"just"
[336]	"fos"	"fa"	"ès"	"pa"	"rabo"
[341]	"dir"	"troba"	"arriba"	"fi"	"crec"
[346]	"lo"	"les"	"ara"	"soldats"	"ma"
[351]	"hom"	"-e"	"al"	"llavò"	"tirar"
[356]	"fet"	"vent"	"mal"	"quatre"	"uis"

[361]	"vol"	"treu"	"eren"	"anar"	"això"
[366]	"garrida"	"portes"	"teua"	"or"	"seu"
[371]	"-a"	"foren"	"cada"	"sortir"	"aigo"
[376]	"aquell"	"erissó"	"-no"	"mateix"	"senyora"
[381]	"pero"	"rei"	"so"	"mestra"	"gerra"
[386]	"-es"	"mirar"	"catalineta"	"dona"	"terra"
[391]	"heu"	"bona"	"havien"	"meua"	"estona"
[396]	"da"	"tu"	"els"	"anaren"	"què"
[401]	"1"	"treure"	"drac"	"o"	"exclama"
[406]	"aquestes"	"pren"	"estava"	"jaia"	"amor"
[411]	"pedra"	"ben"	"dies"	"la"	"sia"
[416]	"arribà"	"tenir"	"crida"	"-ja"	"tros"
[421]	"juan"	"don"	"dur"	"sol"	"an"
[426]	"nou"	"boca"	"-jo"	"bé"	"por"
[431]	"trobar"	"vista"	"portal"	"de"	"tenc"
[436]	"pi"	"moro"	"uns"	"anys"	"dins"
[441]	"gent"	"també"	"riu"	"fins"	"anava"
[446]	"cabeis"	"dia"	"sent"	"hora"	"casar"
[451]	"prendre"	"pogué"	"pas"	"espardenyeta"	"il"
[456]	"casa"	"pot"	"ter"	"per"	"posar"
[461]	"agratiat"	"mort"	"fadeta"	"meu"	"morts"
[466]	"gran"				

```
str(modelo_tomo1)
```

List of 6

```
$ model      :<externalptr>
```

```
$ data       :List of 4
```

```
..$ file      : chr "C:\\Users\\ricuib\\AppData\\Local\\Temp\\RtmpyMuBAp\\textspace_60c4"
```

```
..$ stopwords : chr(0)
```

```
..$ n         : num 81966
```

```
..$ n_vocabulary: num 57716
```

```
$ vocabulary: num 466
```

```
$ success     : logi TRUE
```

```
$ error_log   : chr ""
```

```
$ control     :List of 13
```

```
..$ min_count : int 20
```

```
..$ dim       : int 20
```

```
..$ window    : raw 05
```

```
..$ iter      : raw 32
```

```
..$ lr        : num 0.05
```

```
..$ skipgram  : logi FALSE
```

```

..$ hs          : logi FALSE
..$ negative     : raw 05
..$ sample       : num 0.001
..$ expTableSize: int 1000
..$ expValueMax  : raw 06
..$ split_words  : chr " \n,.-!?:;/\"#$%&'()*+<=>@[\\]^_`{|}~\t\v\f\r"
..$ split_sents  : chr ".\n?!"
- attr(*, "class")= chr "word2vec_trained"

```

```

# Ha retenido
modelo_tomo1$vocabulary

```

```
[1] 466
```

```
#qué palabras son
```

Calculemos la distancia coseno entre los vectores de las palabras

```

matriz_vectores_tomo1 <- as.matrix(modelo_tomo1)
Distancias_coseno_tomo1 <- proxy::dist(matriz_vectores_tomo1,
                                       method = "cosine")

```

Y proyectamos con MDS

```

mds_resultados_tomo1 <- cmdscale(Distancias_coseno_tomo1, k = 2)
plot(mds_resultados_tomo1, main = "MDS de palabras - Tomo
1", xlab = "Dimensión 1", ylab = "Dimensión 2")
text(mds_resultados_tomo1, labels = rownames(matriz_vectores_tomo1), cex = 0.7, pos = 4)

```


1



```
tomo_5_1924 <- read_lines("raw_text/rondalles_ocr_tomo5.txt")
texto5 <- paste(tomo_5_1924, collapse = "\n")
frases5 <- unlist(strsplit(texto5, "[.!?]+"))
class(frases5)
```

```
length(frases5)
```

```
head(frases5)
```

33

```
[3] "\n- s $ NA ds L at Res\n- NN a P re) 21\nl 3 b N ja SO DE ES a x"
[4] " Dar\n- E i x- a as pit n\nds: NI h QU NT rzes sé na\nMa i 4 DE DO DS a a ni\n: A sy NN
[5] " AG Ra\n- - n ) NI AR Tags Ú f aa\nES t NS ) CS\nBi, h A a AP é\nP"
[6] " Dg: I A RA SAN Da a 44\nma , SS À AN AI "
```

Limpiemos algo el texto

```
frases5_limpias <- frases5 %>%
  str_to_lower() %>%
  str_replace_all("[:punct:]", " ") %>%
  str_squish()
head(frases5_limpias)
```

```
[1] "=== página 1 === des d a eet ot ra mir ds re oe or de en qirt 1 40 ns ta ns es ana no l
[2] "mb ib a i dn dt a es ns i ú a el pl y i fi e93"
[3] "s $ na ds l at res nn a p re 21 l 3 b n ja so de es a x"
[4] "dar e i x a as pit n ds ni h qu nt rzes sé na ma i 4 de do ds a a ni a sy nn les ue os l
[5] "ag ra n ni ar tags ú f aa es t ns cs bi h a a ap é p"
[6] "dg i a ra san da a 44 ma ss à an ai"
```

Donde `str_squish()` quita los espacios en blanco al principio, final de frase y los espacios múltiples por un solo espacio. Esto es importante para que el modelo word2vec no tenga que aprender a distinguir entre palabras con espacios adicionales, lo que podría afectar la calidad de los vectores aprendidos.

```
# separemos en frases el texto del tomo V
# utilizaremos un nuevo paquete para la tokenización de frases, el paquete udpipe
library(udpipe)
# tenemos que definir un modelo de lenguaje
modelo <- udpipe_download_model(language = "catalan")
```

Downloading udpipe model from <https://raw.githubusercontent.com/jwiiffels/udpipe.models/ud-2.5-191206/catalan-ancora-ud-2.5-191206.udpipe> to C:/Users/ricuib/Documents/Docencia_25_2019/ancora-ud-2.5-191206.udpipe

- This model has been trained on version 2.5 of data from <https://universaldependencies.org>
- The model is distributed under the CC-BY-SA-NC license: <https://creativecommons.org/licenses/by-sa/4.0>

- Visit <https://github.com/jwijffels/udpipe.models.ud.2.5> for model license details.

- For a list of all models and their licenses (most models you can download with this package under a BY-SA or a CC-BY-SA-NC license) read the documentation at `?udpipe_download_model`. For building a model use `udpipe_train', package = 'udpipe')`

Downloading finished, model stored at 'C:/Users/ricuib/Documents/Docencia_25_26/Rondalles/catala-ancora-ud-2.5-191206.udpipe'

```
modelo <- udpipe_load_model(modelo$file_model)

anotacion <- udpipe_annotate(modelo, x = frases5_limpias)
anotacion_df <- as.data.frame(anotacion)

#limpiemos con txt_clean_word2vec

frases5_clean=txt_clean_word2vec(frases5_limpias)

frases5_clean[100:120]
```

```
[1] "ido ara per castich digue el bon jesus tu no faras mulats"
[2] "sa mula se posa un punt a sa boca i es ver que no n fa de mulats"
[3] "ni n ha fets ni n fara may"
[4] "s 5"
[5] "com es que des tres reys d orient des bellem n hi ha un ab sa barba blanca com es tres
[6] "volgue esser es primer"
[7] "pero com s aixica dels peus del bon jesuset sa barba li va esser tornada blanca blanca
[8] "ah idd2 aquesta oblada se n va dur perque es sent es mes jove volgue esser es de devan
[9] "janauhi voltros a passar es veys a derreral s 4"
[10] "com es que a totes ses festes de la mare de deu hi ha romanins florits p"
[11] "va esser segons conten que sa primera vegada que la purissima hague rentats es drapets
[12] "aquesta tradicio es ge neralissima a mallorca"
[13] "2 la m contaren mon germa andreu i l amo n guillem bulla de manacor"
[14] "pagina 11 4 rondayes mallorquines estendrelos so aixugassen aviat troba s romani que c
[15] "i an es mateix temps com que estufas sa rameta i per rebrelos millor"
[16] "la purissima los hi va estendre demunt"
[17] "que me n direu2 ell es drapets al acte quedaren aixuts i es romani tot florit"
[18] "i per això a totes ses festes de la mare de deu ey ha romanins florits"
[19] "p5"
[20] "com es que no troben nius de cega com la purissimeta i sent jusep fugien cap a i egipte
[21] "el bon jesuset com va veure allo va dir qui es nat ni neixero niu de cega no trobara a
```

4.1.1 Creo el modelo word2vec con el texto del tomo V

```
modelo_tomo5 <- word2vec(  
  x = frases5_clean,  
  type = "cbow",  
  dim = 20,  
  iter = 50,  
  min_count = 20  
)
```

4.1.2 Matriz de vectores del modelo y palabras cercanas

```
emb <- as.matrix(modelo_tomo5)  
head(emb)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]
15	0.4135252	-2.6014745	1.5438010	0.034731645	-0.8457479	0.1694657
aqueixa	0.1978459	1.8283868	-0.2636491	0.591690242	0.5421376	-0.9432620
cormena	-1.0471724	-0.1208518	-0.9753482	-0.006444538	-0.9648570	0.2360384
fum	0.7255266	-1.1261572	-0.2874641	-1.775205731	-1.8711085	1.2213411
lot	-0.7346575	-0.2592845	-0.1461113	0.918859541	-1.0268835	0.1590330
reco	-0.1021611	-2.0844007	0.4829004	-1.359824419	-1.2384262	0.6190550
	[,7]	[,8]	[,9]	[,10]	[,11]	[,12]
15	0.9070613	-1.4499732	-0.8598569	-0.9379018	-0.38108459	0.37864080
aqueixa	0.3135586	0.1304969	-2.1295612	-1.1724153	0.85581827	-0.10504086
cormena	1.6457191	1.8314697	-1.1237509	0.4848526	0.07921144	-1.73163700
fum	-0.2653608	0.1572703	1.2955937	0.4524799	0.06498181	0.20690407
lot	-0.9791616	-1.5779247	-0.2114365	-0.6427133	1.41395152	0.02632455
reco	-0.1932602	-0.7836448	1.6156182	0.3157261	0.37036371	0.75805354
	[,13]	[,14]	[,15]	[,16]	[,17]	[,18]
15	-1.4308039	0.43344423	1.1554812	0.5580655	0.98678780	-0.3561655
aqueixa	0.2483503	-0.41149017	1.5717993	1.3465555	0.62383425	-0.5997534
cormena	-0.5478569	0.01212469	0.5261226	0.7613063	1.30916095	0.3209259
fum	0.8720560	-1.05196095	2.0146122	-0.2410285	-0.09519974	-0.9899036
lot	0.9073138	-1.94352007	1.1218579	0.4886325	-0.51987749	-0.8668688
reco	1.5755060	-1.40062463	0.2084981	0.8347927	-0.25927505	-1.1669894
	[,19]	[,20]				
15	-0.1412945	0.3127030				
aqueixa	-1.4434249	-0.9482002				

```
cormena 1.7585250 0.5651660
fum      0.1441494 0.9795779
lot      -1.5513184 1.4195553
reco     -0.5104864 0.8357186
```

```
emb <- predict(modelo_tomo5, c("bruixa", "vicens", "jesus"), type = "embedding")
emb
```

```
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]
bruixa 0.3894988 -0.09119824 2.1010318 0.1091544 -1.7067509 1.07613969
vicens -1.6732377 -0.16900161 0.4023186 1.2452005 0.1743542 0.08615145
jesus   0.2167197 -0.46833137 1.5154254 1.4457340 -0.3562033 -0.25081635
      [,7]      [,8]      [,9]     [,10]     [,11]     [,12]
bruixa 1.4909796 -1.1281688 0.04458611 -0.07347375 -0.7907072 -0.1340811
vicens 0.3228944 -0.6598502 1.36327803 -0.56959444 -0.7897801 -0.4268444
jesus   0.8622900 0.4721018 0.90333635 -1.42846596 -0.8113902 -1.0690120
      [,13]     [,14]     [,15]     [,16]     [,17]     [,18]
bruixa 0.4613497 -0.8637089 1.0827570 -0.7583559 0.3521872 -0.05170254
vicens 2.3376915 0.1953657 -0.5640748 1.8434530 1.1687702 0.26927349
jesus   0.8469738 -1.1716623 -2.1845548 -0.3037865 -0.7175809 -1.03604186
      [,19]     [,20]
bruixa 2.0394015 -0.45178819
vicens 1.1076453 -0.08975344
jesus  -0.7007034 -0.70649600
```

```
nn <- predict(modelo_tomo5, c("jesus", "bon"), type = "nearest", top_n = 10)
nn
```

```
$jesus
  term1 term2 similarity rank
1  jesus dimoni 0.7457361    1
2  jesus llavo 0.7264431    2
3  jesus mestre 0.7014069    3
4  jesus  any 0.6941200    4
5  jesus posar 0.6893542    5
6  jesus  deu 0.6698478    6
7  jesus just 0.6615888    7
8  jesus poch 0.6561737    8
9  jesus cor 0.6465992    9
10 jesus prou 0.6326223   10
```

```
$bon
  term1 term2 similarity rank
1   bon   aqui  0.8026178    1
2   bon   mon  0.7456552    2
3   bon    st  0.7425943    3
4   bon  feya  0.7247820    4
5   bon  sant  0.7206508    5
6   bon maria  0.7047555    6
7   bon  esta  0.6864038    7
8   bon primer 0.6648559    8
9   bon    sol  0.6457011    9
10  bon    fos  0.6427636   10
```

Calculemos la distancia coseno entre los vectores de las palabras del tomo V

```
head(emb)
```

```
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]
bruixa  0.3894988 -0.09119824  2.1010318  0.1091544 -1.7067509  1.07613969
vicens -1.6732377 -0.16900161  0.4023186  1.2452005  0.1743542  0.08615145
jesus   0.2167197 -0.46833137  1.5154254  1.4457340 -0.3562033 -0.25081635
      [,7]      [,8]      [,9]     [,10]     [,11]     [,12]
bruixa  1.4909796 -1.1281688  0.04458611 -0.07347375 -0.7907072 -0.1340811
vicens  0.3228944 -0.6598502  1.36327803 -0.56959444 -0.7897801 -0.4268444
jesus   0.8622900  0.4721018  0.90333635 -1.42846596 -0.8113902 -1.0690120
      [,13]     [,14]     [,15]     [,16]     [,17]     [,18]
bruixa  0.4613497 -0.8637089  1.0827570 -0.7583559  0.3521872 -0.05170254
vicens  2.3376915  0.1953657 -0.5640748  1.8434530  1.1687702  0.26927349
jesus   0.8469738 -1.1716623 -2.1845548 -0.3037865 -0.7175809 -1.03604186
      [,19]     [,20]
bruixa  2.0394015 -0.45178819
vicens  1.1076453 -0.08975344
jesus   -0.7007034 -0.70649600
```

```
dim(emb)
```

```
[1]  3 20
```

5 Análisis Aplec Tom 1 1915segunda edición

Analizamos en este capítulo el tomo I de 1915, edición dos, que se encuentra en la carpeta `raw_text` los ficheros de interes son.

```
list.files("raw_text/", pattern = "tomo1", ignore.case = TRUE, full.names = TRUE)
```

```
[1] "raw_text/rondalles_ocr_tomo1.csv" "raw_text/rondalles_ocr_tomo1.rds"  
[3] "raw_text/rondalles_ocr_tomo1.txt" "raw_text/tabla_tomo1.csv"
```

El fichero `.csv` contiene un data frame con las páginas del Tomo 1. Este fichero incluye el número de página real: la página 1 corresponde a la portada y la numeración continúa de forma consecutiva hasta el final, con un total de 300 páginas. Esta numeración no coincide con la de la edición, que utiliza numeración romana para el preámbulo y numeración arábica para las rondallas. Por otro lado, el fichero `.txt` contiene el texto en formato raw codificado en UTF-8, con un separador de páginas del tipo:

```
=== Página 1 ===  
presented by  
Mrs B. Huelin, 1  
on bebalfof the late  
Mr D.S. Huelin  
Mar- 2002  
CARA Lo
```

```
=== Página 2 ===  
RONDATES MALLORQUINES
```

```
=== Página 3 ===  
APLEC  
DE  
È D'EN  
JORDI DES RECÓ
```

(ANTONI M2 ALCOVER: PRE.)
SEGONA EDICIÓ
TOM I
AMB LLECENIA DE L' ORDINARI
CIUTAT DE MALLORCA
ESTAMPA D' Es SBBASTIA P1ZA
(915

Leemos estos dos ficheros

```
tomo1 <- read_csv("raw_text/rondalles_ocr_tomo1.csv")
```

Rows: 300 Columns: 3

```
-- Column specification -----  
Delimiter: ","  
chr (1): texto  
dbl (1): pagina  
lgl (1): error
```

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
tabla<- read_csv("raw_text/tabla_tomo1.csv")
```

Rows: 27 Columns: 4

```
-- Column specification -----  
Delimiter: ","  
chr (2): linea, titulo  
dbl (2): pagina, indice
```

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

Veamos el contenido de ambos data frames

```
glimpse(tomo1)
```

Rows: 300

Columns: 3

```
$ pagina <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, ~  
$ texto  <chr> "presented by\r\nMrs B. Huelin, l\r\nnon bebalfof the late\r\nMr~  
$ error  <lgl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
```



```
all(is.na(tomo1$error))
```

```
[1] TRUE
```

Contiene tres columnas: “pagina”, “texto” y “error”. La columna “pagina” indica el número de página, la columna “texto” contiene el texto extraído mediante OCR, y la columna “error” indica si hubo algún error durante el proceso de OCR para esa página, todos están a **NA** no ha habido errores.

Ahora leemos el índice

```
knitr::kable(tabla)
```

linea	pag- ina	titulo	indice
Portada e INICIO	1	Portada e INICIO	1
PROLEG DE LA 1.	5	PROLEG DE LA 1.	5
PROLEG DE LA 2.	16	PROLEG DE LA 2.	16
EN JUANET I ES SET MISSATGES 1	1	EN JUANET I ES SET MISSATGES	26
UN FESTETJADOR. 19	19	UN FESTETJADOR.	44
S' HERMOSURA DEL MON 23	23	S' HERMOSURA DEL MON	48
SA FIA DES CARBONERET 35	35	SA FIA DES CARBONERET	60
EN MARTÍ TACÓ . 44	44	EN MARTÍ TACÓ .	69
ES CA D'EN BUA I ES MOIX D'EN PEJULÍ. 57	57	ES CA D'EN BUA I ES MOIX D'EN PEJULÍ.	82
N'ESTEL D' OR 63	63	N'ESTEL D' OR	88
NA MAGRANETA. 84	84	NA MAGRANETA.	109
SA JAIA XELOC I SA JAIA BIGALOT 99	99	SA JAIA XELOC I SA JAIA BIGALOT	124
EN JUANET DE SA GERRA 107	107	EN JUANET DE SA GERRA	132
ES TRES GERMANS I ES NOU GEGANTS. 114	114	ES TRES GERMANS I ES NOU GEGANTS.	139
EN PERE DE SA BUTZA 128	128	EN PERE DE SA BUTZA	153
ES SET CEROS 133	133	ES SET CEROS	158
ES SEGADOR I SA BEATA 146	146	ES SEGADOR I SA BEATA	171
EN SALOM I ES BAL'LE. 150	150	EN SALOM I ES BAL'LE.	175
N AGRACIAT 165	165	N AGRACIAT	190
ES CASTELL D'IRÁS I NO TORNARÁS 174	174	ES CASTELL D'IRÁS I NO TORNARÁS	199
Es QUATRE GERMANS 213	213	Es QUATRE GERMANS	238

linea	pag- ina	titulo	indice
S' HOMO I ES LLEÓ 228	228	S' HOMO I ES LLEÓ	253
N' ESPARDENYET 231	231	N' ESPARDENYET	256
Es DOs BESSONS 244	244	Es DOs BESSONS	269
SA RABOA I S' ERISSÓ 256	256	SA RABOA I S' ERISSÓ	281
SA RONDAIA D' EN VIT 269	269	SA RONDAIA D' EN VIT	294
BON-JESÚS I ETS ALTRES	273	BON-JESÚS I ETS ALTRES	298
APÒSTOLS.. 273		APÒSTOLS..	

Las variables son “linea”, “pagina”, “titulo” e “indice”. La variable “linea” contiene el título de cada sección o capítulo, la variable “pagina” indica la página en la que se encuentra esa sección o capítulo, la variable “titulo” es una copia de “linea” y la variable “indice” indica el número de página real en el documento, que NO se corresponde con la numeración del tomo.

6 Corpus Tomo 1

Construyamos el corpus de este aplec separando cada capítulo

```
corpus_tomo1 <- tabla %>%
  mutate(
    texto = map2_chr(
      indice,
      lead(indice, default = nrow(tomo1) + 1),
      ~ {
        start <- .x
        end <- .y - 1
        page_texts <- tomo1 %>%
          filter(pagina >= start, pagina < end) %>%
          pull(texto)
        paste(page_texts, collapse = "\n")
      }
    )
  ) %>%
  select(linea, pagina, titulo, texto)
```

La rondalla más corta es la número 4 que está en la entrada 7 de la tibble , que se titula “Rondalla de la filla del rei de les flors”. Veamos su texto

```
cat(head(corpus_tomo1$texto[7]))
```

```
P ecaomos ame dopoec entens mb
SA FIA DES CARBONERET '
--bo- De ea --
```

a IXÒ era un carboner que tenía un fil, una

GA fia casada i dues tadrines.

LS Un dia el Rei, cassant cassant, passa
per davant sa barraca des carboner, i troba sa seua
fia darrera, una fadrineta de setze anys, sa més

galanxona, que havia nom Catalineta.

El Rei, com la va veure, va romandre embadalit, ili digué:

-Alabat sia Deu. 1

-Pera sempre, senyor Reit diu s' al'lotona.

-e Quina la tas2 diu el Rei.

- Quin damunt davall són, diu ella.

-j Damunt davall són/ s'esclamà el Rei, i reparà una Sarria que feia embalum.

-eQue hi ha dins aquella sarria2 demanà.

-Xerrim baix, digué Na Catalineta.

-j Xerrim baixl 's' esclamá el Rei, sense que li ocorregués que poria esser allò i va dir: - -

-éA on és ton pare

- A treure gent de ca-seua, diu ella.

Il La'm contú la mateixa criada de ca-nostre, N' Antonina Cordera.

36 RONDAIES MALLORQUINES

o -èl ta mare2 diu el Rei. :

-À plorar es pler de 1 any passat, respòn s' al-lota.

-el es teu germà2 diu el Rei.

-A cassar. Deixa sa cassa que ha agafada, i du sa que no ha poguda agafar, diu ella.

El Rei quedà tot contús amb aquesta partida d2 coses que aquella pitxorina li havia entlocades.

-bDiràs a ton pare que venga es vespre a veure 'm, li digué i se 'n anà.

Es vespre es carboner se presenta a ca 1 Rei, i diu:

ee -BEona nittenga, senyor Rei. cEstà bonet2 Que vol de mí2 :

ee -Bo estic, gracies a Deu, diu el Rei. Som passat avui per sa teua barraca, i tens una tia més viva que una centella: Li he tetes un parei de preguntes, i m' ha respost d'una manera que m' ha deixat 'contús: M'ha dit que cuinavà damunt davall són.

-Tenia "raó, diu es carboner: Eren ciurons, que, quant \$' olla bull, pugen i davallen, i un cop són damunt i un cop davall.

-iEl diantre ès aquesta al'lotal diu el Rei. I m' ha dit també que dins una sarria hi havia .xerrim baix.

-Es verl diu es carboner: e-hi havia s' altra fia despujada, porque totes dues no més tenen un vestit, el duen un dia per.hom, i Sa qui no 'l du, està dins sa sarria, i, en venir ningú estern, xerra baix, porque no se temin d'ella.

-i El diantre es aquesta al'lotal diu el Rei. Í m' ha dit llavò que tu eres a treure gent de ca-seua.
' -Es ver, diu es carboner: era a treure rabassons.

SA FIA DES CARBONERET 37

-iSí que endevinava idòl diu el Rei. I llavò m' ha dit que sa mare era a plorar es pler de 1 any passat. Ú

-I massa que hi eral diu es carboner. Entany . casérem una tia, i despuisahir se morí, al cel sía ella i tots los morts, i sa dona hi era, ja hu veu, per donar cap. Í ella i noltros ploràvem. i . ploram, es pler que l'any passat tenguérem des casament. L l es carbòneret va rompre en plors. -, ..- ,,

-No plores, digué el Rei. Deu ho ha fet, i ell sab que fa, i no pot errar. Una altra cosa'm' ha dita aquella polisseta, i ès sa que m' ha deixat més contús. M' ha dit que es seu germà. era a, cassar,. i que deixava sa cassa que havia agafada, i duia sa que no havia poguda agafar... ,A veure qui hu entén an aixòl dèy

-Jo le hi diré, diu es carboner: era a esplugar-se: deixava morts es pois qne agafava, i duia damunt el còs tots es qui no havia poguts agatar.

-i El dintre es aquesta al'lotal digué el Rei tot admirat. Mira, si no la puc contondre, m'he :de casar. amb ella. 1 P a

l eque ta ell Àgata tres ous, los trenca dins, un plat, los rebat una bona estona i diu an .es carboneret. l id

-Jèsi du aquests ous a sa teua tia. Que, les pos, i tendrem aviram en casar-mos. o Res ay

-iPobre tieta meual scom n'ha de sortir: .d' aquesta2 deia es carboneret quant. se "n ternaya a sa barraca. : d'AS qe

E-hi arriba, conta es pas a sa ,fia, i ella .s'exclama: pat

-PD' això estau embarassat2. Esperau, veureu. Agata unes quantes grapades de civada, la mol ben mòlta, i li diu:

38 RONDAIES MALLORQUINES

e-Jau aquesta farina. Duis-la an el Rei. Que la sembr, i tendrem civada per dar a s'aviram en casar-mos.

- Es carboneret se'n hi va, va fer sa comanda de Na Catalina, i el Rei va quedar sense paraula.

4 Després de pensar-hi molt, pren un tros de. roba, el fa bocins menuts menuts, com una ungla.

-Jès, li digué. Du-los a sa teua fia, que tassa es menudai per quant mos casem i tenguem cap infant. :

: -3jPobre tieta meual ccom n'ha de sortir d' aquestal deia es carboneret tot enfadat, quant se en:tornava a sa barraca. ds

E-hi arriba, dona a Na Catalineta sa comanda del Rei, i ella s' exclama:

-dAixò ès tot

Agafa un parei d' ensenais, los esmenuca tot lo que pot, los dona a son pare, i li diu:

-Jau, duis-los an el Rei, i que 'n tassa 's bres per un Si a cas...

Ell ja ès partit cap a ca I Rei, li dona sa comanda de Na Catalina, i el Rei iquè havia de sebre respondrel Se: posa pensa qui pensa, per veure com l'apuraria, i a la fi, pren un paner, i diu: l

-Jès, du 'l a sa teua fia, i que l'umpli de riaies.

-iPobre fia meual jaquesta vegada no 'n surtl deia es carboneret, tornant-se 'n a. sa barraca. l amb so cap dins es paner se posava after ija ja jal riu que riu amb unes riaies lo més forsades, i jque havia d'omplires panerl i Tant com es moix

Tot-d' una que arriba í Na Catalineta el sent, li diu:

-iD' això estau embarassatP Anau a agatar tres dotzenes d' aucellons. Los posau . dins aquest pa-

SA FIA DES CARBONERET 39

ner, tapau damunt amb un pedàs, vos n'anau a ca 'l Rei, esperau que estiga en taula, li entregau es paner de part mea, i que 'l destap.

Es carboneret e-hu va fer així. Justament el Rei tenia una bona partida de convidats. Fa destapar es paner, surt aquell esbart d' aucellons, i uns. se tiren per dalt ses gerretes de s'aigo i es garrafs de ví, altres voletetjant feren plats i tassons, altres

peguen per demunt es cap i ses espal'les des convidats, altres los freguen amb ses ales, front, galtes i oreies, i hi hagué qualque nas afavorit. que

se'n va dur més d'un quern de: titorades, i ven-
guen esquitxos, i raigs, i rois, taques, i crits, i
renou, i tot-hom no pogué estar que no esclafís
de riure, i cuidaden a ter ui de riaies.:

/ El Rei, apurat de tot, veent que sempre queda-
va davall, a torsa de sucra ets ais, se 'n va treure
una que se creia que havia de capturar sa carbo-
nereta..-

-No res, va dir a son pare. Diga-li que veng
ni vestida ni sensa vestir, ni pes camí ni fora
camí, ni cualcant ni a peu.

-jPobre tia meua! jAquesta vegada no 'n surtsi
deia es carboneret, tot entadat, tornant-se 'n a sa
barraca.

Quant e-hi va esser, i Na Catalina el sentí, li
diu:

-eD' això estau embarassat? Anau a Ses Pla-
nes, menau un boc muntanyenc, ben seuvatgí.

Son pare hi va, compra es boc, i le hi mena.
Ella se desmuda, s'embolica un filacs, se posa
damunt s' animal, i ja es partida cap a ca 'l Rei.

1 Possessió de Sant Llorens des Cardessar.

3

4) Ò RONDAIES MALLORQUINES

I Es boc, ja hu. crec, feia bots.i escaravits, i tot eren
fues i xecalines. Assetsuaixí servava camí, asset-
suaixí no 'n servava: la tomava, ella s' hi tornava:
posar damunt: i la tornava tomar, i ella s' hi tor-
nava posar.

De manera que ni anava vestida ni sensa vestir,

ni p'es camí ni tora camí, ni cualcant ni a peu.

-El-Rei, com la va veure, digué:

-Paraula de Rei no pot mentir. No t' he poguda
confondre: mos hem de casar.

-BEll que hu véssem, va dir ella.

-Aviat ho veurem, si Deu ho vol, diu el Rei. È
Però va amb uns pactes.

-eQuins pactes son aquests² diu ella.

-Que no pots donar conseis a negú, diu el Rei.
Si 'n dones cap, te 'n hauràs de tornar a sa barraca
de ton pare.

-gl no me 'n he de porer dur resè diu ella.

-Vaja, per que no 't pugues queixar, te'n po-
dràs dur una joia, diu el Rei.

-iUna no més^P égrossa o petita^P diu ella.

-No res, sa que tu voldràs, diu el Rei.

Ella hiipensé'una estoneta, i s' exclama: .,

- Feta està sa barrina. /

Se casaren, el Rei tirà sa casa per sa finestra,
e-hi hagué un:ast i olla de lo més alt de punt, i
es sarau que 'S va fer no hu poren dir persones
nades.

Des cap d'una mesada, amàú a ròmandre a ca ll
Rei un mahonès amb una ego.

-eA on pos aquesta: bistieta^P digué. ,

-Dins s' estable, li varen respondre.

: E-hi guaita, i hi veu un cavall, i diu:

-eQue l'he de posar devora es cavall2

SA FIA DES CARBONERET 41

-Posau-le-hi, li varen dir...

Lla hi posà. ,

Lo endemòà matí s' ego va haver feta una pollina::
o 3 El Rei la volía, perque. deia que, essent nada
dins s' estable a on no hi havia altra bístia seua
més que es cavall, per forsa l'havía d' haver feta

es cavall.

-Pero isi hi havia s' ego des mahonèsi li deien.

-No m'empatx de raons, deia ell. No m'heu
de dir voltros a on ès el Carme ni el Sant Esperit.
Jo no tenia altra bístia dins s'estable, cès nada
una pollina2 Idò ès des cavall. É

Es criats, com el veren tan encabotat, el deixa-
ren anar. R

Es mahonès anà també ben alerta a fer-li
cuantra.

La Reina hu va sebre, i li mostra una bassa seca
que hi havia allà aprop, i li diu:

l -Anau-hi amb una canyeta i una ginya, i teís

com que pescar. El Rei, en anar-se'n a sa cassada,

en .passarà, i vos dirà:-eQue feís2 Il heu de dir:

-Pesc. -cQue pescau2 dirà ell. -Sardines, heu

de dir vos. -eQuin possible ès, dirà ell, sensa aigo

a sa bassa, pescar-hi sardines2 I vos: heu de dir:

-Tant possible ès, sensa haver-hi aigo, agafar-hi sardines, com que un cavall fassa pollines.

Es mahonès seguí es consei de la Reina.

Passà el Rei per devora sa bassa, el veu amb sa canyeta i sa ginya lo mateix d'un pescador que espera una gran peixetada, i li diu: pea

-el. ara que tas

-Pescl diu es mahonès. us

-eiQuè pesquesP diu el Rei, ,

-Sardinesi diu es mahonès. qe ES de

42 RONDAIES MALLORQUINES

-jDe tros de banci diu el. Rei. iNo hi ha una gota..d'aigo dins sa bassa, i hi vols agafar sardinesl équin possible es que n' agatis cap2

-Tant possible ès, digué es mahonès, sensa haver-hi aigo agatar-hi sardines, com que un cavall fassa pollines.

El Rei va quedar taiat davant aquesta sortida, i per desfer-se d'aquells trumíos, digué:

-Anau a ca-meua, i menau-vos-ne s' ego i sa pollina i espitxau-vos més que de pressa cap a.ca-vostra.

Es mahonès e-hu va ter així, i el Rei pensà entre sí mateix:

-Ja ès la Reina que li ha aconselat que "m fés aquesta.

Gira en redó cap a ca-seua, i li diu:

-Ets tu. Negú pot esser més que tu.

-gl ara2 diu la Reina. I /

-Suaral diu el Rei. Has donat un consei an es mahonès: no hu pots negar..

-Le hi he donat per que no. tesses s' injusticia. de prendre-li sa pollinal diu la Reina.

-No m' empatx de raonsi diu el Rei. L' has donat i no 'l pories donar. éSabs quins son es pactes que 't vaig posar quant mos casàrem2

-Sí. diu la Reina.

-lIdò te 'n pots anar en volert diu el Rei...

-ç Que no porem dinar abans2 diu la Reina.

-No res idò, diu el Rei: dinarem, i llavò te 'n aniràs.

Dinaren, i sa traidora li donà dormissons.

Quant el tengué ben adormit, ta enganxar es cotxo, le hi posa de dins, i dona orde de partir cap a sa'barraca de son pare.

Cómo se ve el tla OCR ha funcionado bastante bien, aunque hay algunos errores de reconocimiento, como “RONDATES” en lugar de “RONDALLES” o “MAYORQUINES” en lugar de “MALLORQUINES”. Sin embargo, el texto es legible y se puede trabajar con él para realizar análisis posteriores.

Podéis curar lo errores más fáciles con ecpresiones regulares

Por ejemplo, para corregir “RONDATES” a “RONDALLES” y “MAYORQUINES” a “MALLORQUINES”, podríamos usar el siguiente código:

```
corpus_tomo1 <- corpus_tomo1 %>%  
  mutate(
```

```

    texto = str_replace_all(texto, c(
      "RONDATES" = "RONDALLES",
      "MAYORQUINES" = "MALLORQUINES"
    ))
  )

```

-No m' empatx de raonsi diu el Rei. L' has donat i no 'l poríes donar. éSabs quins son es pactes que 't vaig posar quant mos casàrem2

Por ejemplo aquí podríamos corregir los silabeados como “don-at” en el fin de línea con el siguiente código para corta palabra partidas de esta manera:

```

library(stringr)
corpus_tomo1 <- corpus_tomo1 %>%
  mutate(
    texto = str_replace_all(texto, "(\\p{L}+)-\\s*\\n\\s*(\\p{L}+)", "\\1\\2")
  )

```

Efectivamente ahora

```

cat(head(corpus_tomo1$texto[7]))

```

P ecaomos ame dopoec entens mb
 SA FIA DES CARBONERET '
 --bo- De ea --

a IXÒ era un carboner que tenia un fil, una

GA fia casada i dues tadrines.
 LS Un dia el Rei, cassant cassant, passa
 per davant sa barraca des carboner, i troba sa seua
 fia darrera, una fadrineta de setze anys, sa més
 galanxona, que havia nom Catalineta.

El Rei, com la va veure, va romandre embadalit,
 ili digué:

-Alabat sia Deu. l

-Pera sempre, senyor Reit diu s' al'lotona.

-e Quina la tas2 diu el Rei.

- Quin damunt davall són, diu ella.

-j Damunt davall són/ s'esclamà el Rei, i reparà una Sarria que feia embalum.

-eQue hi ha dins aquella sarria2 demanà.

-Xerrim baix, digué Na Catalineta.

-j Xerrim baixl 's' esclamá el Rei, sense que li
ocorregués que poria esser allò i va dir: - -

-éA on ès ton pare

- A treure gent de ca-seua, diu ella.

Il La'm contú la mateixa criada de ca-nostre, N' Antonina Cordera.

36 RONDAIES MALLORQUINES

o -èl ta mare2 diu el Rei. :

-À plorar es pler de l any passat, respòn s' allota.

-el es teu germà2 diu el Rei.

-A cassar. Deixa sa cassa que ha agafada,
i du sa que no ha poguda agafar, diu ella.

El Rei quedà tot contús amb aquesta partida d2
coses que aquella pitxorina li havia entlocades.

-bDiràs a ton pare que venga es vespre a veure 'm, li digué i se 'n anà.

Es vespre es carboner se presenta a ca l Rei, i
diu:

ee -BEona nittenga, senyor Rei. cEstà bonet2 Que
vol de mí2 :

ee -Bo estic, gracies a Deu, diu el Rei. Som passat avui per sa teua barraca, i tens una tia
viva que una centella: Li he tetes un parei de preguntes, i m' ha respost d'una manera que m
deixat 'contús: M'ha dit que cuinavà damunt davall

són.

-Tenia "raó, diu es carboner: Eren ciurons,
que, quant \$' olla bull, pugen i davallen, i un cop
són damunt i un cop davall.

-iEl diantre és aquesta al'lotal diu el Rei. I m'
ha dit també que dins una sarria hi havia .xerrim
baix.

-Es ver! diu es carboner: e-hi havia s' altra fia
despuada, porque totes dues no més tenen un
vestit, el duen un dia per.hom, i Sa qui no 'l du, està dins sa sarria, i, en venir ningú es
baix, porque no se temin d'ella.

-i El diantre es aquesta al'lotal diu el Rei. Í m'
ha dit llavò que tu eres a treure gent de ca-seua.
' -Es ver, diu es carboner: era a treure rabassons.

SA FIA DES CARBONERET 37

-iSí que endevinava idòl diu el Rei. I llavò m'
ha dit que sa mare era a plorar es pler de l any
passat. Ú

-I massa que hi eral diu es carboner. Entany .
casérem una tia, i despuisahir se morí, al cel sía
ella i tots los morts, i sa dona hi era, ja hu veu,
per donar cap. Í ella i noltros ploràvem. i . ploram,
es pler que l'any passat tenguérem des casament. L
l es carbòneret va rompre en plors. -, ..- ,,
-No plores, digué el Rei. Deu ho ha fet, i ell
sab que fa, i no pot errar. Una altra cosa'm' ha
dita aquella polisseta, i és sa que m' ha deixat més
contús. M' ha dit que es seu germà. era a, cassar,.
i que deixava sa cassa que havia agafada, i duia
sa que no havia poguda agafar... ,A veure qui hu
entén an aixòl dèy

-Jo le hi diré, diu es carboner: era a esplugarse: deixava morts es pois qne agafava, i duia

-i El diantre es aquesta al'lotal digué el Rei tot
admirat. Mira, si no la puc contondre, m'he :de
casar. amb ella. 1 P a

l eque ta ell Àgata tres ous, los trenca dins, un
plat, los rebut una bona estona i diu an .es carboneret. l id

-Jèsi du aquests ous a sa teua tia. Que, les pos,

i tendrem aviram en casar-mos. o Res ay
-iPobre tieta meual scom n'ha de sortir: .d'
aquesta2 deia es carboneret quant. se "n ternaya a
sa barraca. : d'AS qe
E-hi arriba, conta es pas a sa ,fia, i ella .s'exclama: pat
-PD' això estau embarassat2. Esperau, veureu.
Agata unes quantes grapades de civada, la mol
ben mòlta, i li diu:

38 RONDAIES MALLORQUINES

e-Jau aquesta farina. Duis-la an el Rei. Que la
sembr, i tendrem civada per dar a s'aviram en
casar-mos.

- Es carboneret se'n hi va, va fer sa comanda de
Na Catalina, i el Rei va quedar sense paraula.

4 Després de pensar-hi molt, pren un tros de. roba,
el fa bocins menuts menuts, com una ungla.

-Jès, li digué. Du-los a sa teua fia, que tassa
es menudai per quant mos casem i tenguem cap
infant. :

: -3jPobre tieta meual ccom n'ha de sortir d'
aquestal deia es carboneret tot enfadat, quant se
en:tornava a sa barraca. ds

E-hi arriba, dona a Na Catalineta sa comanda
del Rei, i ella s' exclama:

-dAixò ès tot

Agafa un parei d' ensenais, los esmenuca tot lo
que pot, los dona a son pare, i li diu:

-Jau, dui-los an el Rei, i que 'n tassa 's bres
per un Si a cas...

Ell ja ès partit cap a ca I Rei, li dona sa comanda de Na Catalina, i el Rei iquè havia de s
respondrel Se: posa pensa qui pensa, per veure
com l'apuraria, i a la fi, pren un paner, i diu: l

-Jès, du 'l a sa teua fia, i que l'umpli de riaies.

-iPobre fia meual jaquesta vegada no 'n surtl
deia es carboneret, tornant-se 'n a. sa barraca. l
amb so cap dins es paner se posava after ija ja jal
riu que riu amb unes riaies lo més forsades, i jque
havía d'omplires panerl i Tant com es moix

Tot-d' una que arriba í Na Catalineta el sent,
li diu:

-iD' això estau embarassatP Anau a agatar tres
dotzenes d' aucellons. Los posau . dins aquest paSA FIA DES CARBONERET 39
ner, tapau damunt amb un pedàs, vos n'anau a
ca 'l Rei, esperau que estiga en taula, li entregau
es paner de part mea, i que 'l destap.

Es carboneret e-hu va fer així. Justament el Rei
tenía una bona partida de convidats. Fa destapar
es paner, surt aquell esbart d' aucellons, i uns. se
tiren per dalt ses gerretes de s'aigo i es garrafs
de ví, altres voletetjant feren plats i tassons, altres
peguen per demunt es cap i ses espal'les des convidats, altres los freguen amb ses ales, from

se'n va dur més d'un quern de: titorades, i venguen esquitxos, i raigs, i rois, taques, i cr
renou, i tot-hom no pogué estar que no esclafís
de riure, i cuidaden a ter ui de riaies.:

/ El Rei, apurat de tot, veent que sempre quedava davall, a torsa de sucra ets ais, se 'n va
una que se creia que havia de capturar sa carbonereta..-

-No res, va dir a son pare. Diga-li que venga
ni vestida ni sensa vestir, ni pes camí ni fora
camí, ni cualcant ni a peu.

-jPobre tia meual jAquesta vegada no 'n surtsi
deia es carboneret, tot entadat, tornant-se 'n a sa
barraca.

Quant e-hi va esser, i Na Catalina el sentí, li
diu:

-eD' això estau embarassat2 Anau a Ses Planes, menau un boc muntanyenc, ben seuvatgí.

Son pare hi va, compra es boc, i le hi mena.
Ella se desmuda, s'embolica un filacs, se posa
damunt s' animal, i ja es partida cap a ca 'l Rei.

1 Possessió de Sant Llorens des Cardessar.

3

4) Ò RONDAIES MALLORQUINES

I Es boc, ja hu. crec, feia bots.i escaravits, i tot eren
fues i xecalines. Assetsuaixí servava camí, assetsuaixí no 'n servava: la tomava, ella s' hi
posar damunt: i la tornava tomar, i ella s' hi tornava posar.

De manera que ni anava vestida ni sensa vestir,

ni p'es camí ni tora camí, ni cualcant ni a peu.

-El-Rei, com la va veure, digué:

-Paraula de Rei no pot mentir. No t' he poguda
confondre: mos hem de casar.

-Bell que hu véssem, va dir ella.

-Aviat ho veurem, si Deu ho vol, diu el Rei. È
Però va amb uns pactes.

-eQuins pactes son aquests2 diu ella.

-Que no pots donar conseis a negú, diu el Rei.
Si 'n dones cap, te 'n hauràs de tornar a sa barraca
de ton pare.

-gl no me 'n he de porer dur resè diu ella.

-Vaja, per que no 't pugues queixar, te'n podràs dur una joia, diu el Rei.

-iUna no mésP égrossa o petitaP diu ella.

-No res, sa que tu voldràs, diu el Rei.

Ella hiipensé'una estoneta, i s' exclama: .,

- Feta està sa barrina. /

Se casaren, el Rei tirà sa casa per sa finestra,
e-hi hagué un:ast i olla de lo més alt de punt, i
es sarau que 'S va fer no hu poren dir persones
nades.

Des cap d'una mesada, amàú a ròmandre a ca ll
Rei un mahonès amb una ego.

-eA on pos aquesta: bistietap digué. ,

-Dins s' estable, li varen respondre.

: E-hi guaita, i hi veu un cavall, i diu:

-eQue l'he de posar devora es cavall2

SA FIA DES CARBONERET 41

-Posau-le-hi, li varen dir...

Lla hi posà. ,

Lo endemòà matí s' ego va haver feta una pollina::
o 3 El Rei la volía, porque. deia que, essent nada
dins s' estable a on no hi havia altra bistia seua
més que es cavall, per forza l'havia d' haver feta
es cavall.

-Pero isi hi havia s' ego des mahonèsi li deien.

-No m'empatx de raons, deia ell. No m'heu
de dir voltros a on ès el Carme ni el Sant Esperit.
Jo no tenia altra bistia dins s'estable, cès nada
una pollina2 Idò ès des cavall. É

Es criats, com el veren tan encabotat, el deixaren anar. R

Es mahonès anà també ben alerta a fer-li
cuantra.

La Reina hu va sebre, i li mostra una bassa seca
que hi havia allà aprop, i li diu:

l -Anau-hi amb una canyeta i una ginya, i teís
com que pescar. El Rei, en anar-se'n a sa cassada,
en .passarà, i vos dirà:-eQue feís2 Il heu de dir:
-Pesc. -cQue pescau2 dirà ell. -Sardines, heu
de dir vos. -eQuin possible ès, dirà ell, sense aigo
a sa bassa, pescar-hi sardines2 I vos: heu de dir:
-Tant possible ès, sense haver-hi aigo, agafar-hi
sardines, com que un cavall fassa pollines.

Es mahonès seguí es consei de la Reina.

Passà el Rei per devora sa bassa, el veu amb sa
canyeta i sa ginya lo mateix d'un pescador que
espera una gran peixetada, i li diu: pea

-el. ara que tas

-Pescl diu es mahonès. us

-eiQuè pesquesP diu el Rei, ,

-Sardinesi diu es mahonès. qe ES de

42 RONDAIES MALLORQUINES

-jDe tros de banci diu el. Rei. iNo hi ha una
gota..d'aigo dins sa bassa, i hi vols agafar sardinesl équin possible es que n' agatis cap2

-Tant possible ès, digué es mahonès, sense
haver-hi aigo agatar-hi sardines, com que un cavall
fassa pollines.

El Rei va quedar taiat davant aquesta sortida, i
per desfer-se d'aquells trumíos, digué:

-Anau a ca-meua, i menau-vos-ne s' ego i sa
pollina i espitxau-vos més que de pressa cap a.cavostra.

Es mahonès e-hu va ter així, i el Rei pensà entre sí mateix:

-Ja és la Reina que li ha aconselat que "m fés
aquesta.

Gira en redó cap a ca-seua, i li diu:

-Ets tu. Negú pot esser més que tu.

-gl ara2 diu la Reina. I /

-Suaral diu el Rei. Has donat un consei an es
mahonès: no hu pots negar..

-Le hi he donat per que no. tesses s' injusticia.
de prendre-li sa pollinal diu la Reina.

-No m' empatx de raonsi diu el Rei. L' has donat i no 'l pories donar. éSabs quins son es pa
que 't vaig posar quant mos casàrem2

-Sí. diu la Reina.

-lIdò te 'n pots anar en volert diu el Rei...

-ç Que no poreu dinar abans2 diu la Reina.

-No res idò, diu el Rei: dinarem, i llavò te 'n
aniràs.

Dinaren, i sa traidora li donà dormissons.

Quant el tengué ben adormit, ta enganxar es
cotxo, le hi posa de dins, i dona orde de partir cap
a sa'barraca de son pare.

7 Práctica evaluable por grupos

Enunciado provisional

El texto ya lo he procesado en este github y he generado un quarto book (ya lo explicaré)

Cada grupo coge un aplec y lo procesa

1. Cargar el texto y preprocesarlo (tokenización, limpieza, etc.)
2. Analizar la frecuencia de palabras en el aplec.
3. Estudiar la ley de Zipf en el aplec.
4. Comparar los resultados con otros aplecs o con el texto completo.
5. Construir un corpus formado por las rondallas y calcular el tf-idf y 7. Estudiar las palabras más características de las rondallas
6. Hacer un tópico de LDA sobre el corpus de rondallas y estudiar los temas más relevantes.
7. Estudiar el paquete word2vec y proyectar las palabras de las rondallas en $\mathbb{R}^n$ y luego proyectar con algunos de los algoritmos t-SNE o UMAP o MDS algún conjunto de palabras.
8. Calcular la matriz de distancias de las palabras y construir un grafo podando el grafo completo con un umbral de similitud. Estudiar la comunidad de palabras y las palabras más centrales en el grafo.
9. Presentar los resultados en un informe o presentación.

7.1 Solución

7.1.1 Tokenización y limpieza

Cargamos los datos y los preprocesamos con el siguiente código:

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
```

```
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(stringr)
```

```
lista_tomos=dir("raw_text", pattern = "rondalles_ocr_tomo.*\\.csv")
path_lista_tomos=paste0("raw_text/",lista_tomos)
path_lista_tomos
```

```
[1] "raw_text/rondalles_ocr_tomo1.csv" "raw_text/rondalles_ocr_tomo2.csv"
[3] "raw_text/rondalles_ocr_tomo3.csv" "raw_text/rondalles_ocr_tomo5.csv"
[5] "raw_text/rondalles_ocr_tomo8.csv"
```

```
corpus <- sapply(path_lista_tomos,function(x){ read_csv(x) %>% mutate(
  texto = str_replace_all(texto, c(
    "RONDATES" = "RONDALLES",
    "MAYORQUINES" = "MALLORQUINES"
  )),
  texto = str_replace_all(texto, "(\\p{L}+)-\\s*\\n\\s*(\\p{L}+)", "\\1\\2"))})
```

```
Rows: 300 Columns: 3
```

```
-- Column specification -----
Delimiter: ","
chr (1): texto
dbl (1): pagina
lgl (1): error
```

```
i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
Rows: 326 Columns: 3
```

```
-- Column specification -----
Delimiter: ","
chr (1): texto
dbl (1): pagina
lgl (1): error
```

```
i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```

Rows: 330 Columns: 3
-- Column specification -----
Delimiter: ","
chr (1): texto
dbl (1): pagina
lgl (1): error

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
Rows: 207 Columns: 3
-- Column specification -----
Delimiter: ","
chr (1): texto
dbl (1): pagina
lgl (1): error

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
Rows: 175 Columns: 3
-- Column specification -----
Delimiter: ","
chr (1): texto
dbl (1): pagina
lgl (1): error

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.

```


8 Solución práctica

Unas ideas para la carga de datos y la solución de la práctica.

8.1 Carga de datos

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2     4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr       1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

Cargaremos cada todo de uno en un primer paso para luego construir el corpus completo. En este caso, el proceso de construcción del corpus es un poco más laborioso, ya que cada rondalla se encuentra distribuida a lo largo de varias páginas y no tenemos un formato estructurado que nos permita identificar fácilmente los límites de cada rondalla. Por ello, utilizaremos la tabla de contenidos (que se encuentra en un formato estructurado) para identificar los límites de cada rondalla y luego extraer el texto correspondiente a cada una de ellas.

8.2 Tomo 1

Para el tomo 1 lo ficheros

```
dir("raw_text", pattern = "tomo1")
```

```
[1] "rondalles_ocr_tomo1.csv" "rondalles_ocr_tomo1.rds"
[3] "rondalles_ocr_tomo1.txt" "tabla_tomo1.csv"
```

Leeremos el que tienen la información de cada página y el índice de contenidos y el número de página real en el documento, que NO se corresponde con la numeración del tomo. Algunos (o todos los tomos) incorporan: la portada (pág 1), y los preambulos numerados en números romanos que a veces incluyen un índice al que llaman tabla al principio (en el tomo VIII está al final). Para facilitar esto tenemos el fichero de la TABLA para arreglar, ver el ejemplo del tomo I, como apilar cada rondalla para una entrada del corpus.

```
#página por linea
tomo1 <- read_csv("raw_text/rondalles_ocr_tomo1.csv")
```

```
Rows: 300 Columns: 3
-- Column specification -----
Delimiter: ","
chr (1): texto
dbl (1): pagina
lgl (1): error

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
# indice
tabla1 <- read_csv("raw_text/tabla_tomo1.csv")
```

```
Rows: 27 Columns: 4
-- Column specification -----
Delimiter: ","
chr (2): linea, titulo
dbl (2): pagina, indice

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
t2=tabla1[-c(1:3),]
t2$final=c(t2$indice[-1]-1,300)
knitr::kable(t2)
```

linea	pag- ina	titulo	in- dice	final
EN JUANET I ES SET MISSATGES 1	1	EN JUANET I ES SET MISSATGES	26	43
UN FESTETJADOR. 19	19	UN FESTETJADOR.	44	47
S' HERMOSURA DEL MON 23	23	S' HERMOSURA DEL MON	48	59
SA FIA DES CARBONERET 35	35	SA FIA DES CARBONERET	60	68
EN MARTÍ TACÓ . 44	44	EN MARTÍ TACÓ .	69	81
ES CA D'EN BUA I ES MOIX D'EN PEJULÍ. 57	57	ES CA D'EN BUA I ES MOIX D'EN PEJULÍ.	82	87
N'ESTEL D' OR 63	63	N'ESTEL D' OR	88	108
NA MAGRANETA. 84	84	NA MAGRANETA.	109	123
SA JAIA XELOC I SA JAIA BIGALOT 99	99	SA JAIA XELOC I SA JAIA BIGALOT	124	131
EN JUANET DE SA GERRA 107	107	EN JUANET DE SA GERRA	132	138
ES TRES GERMANS I ES NOU GEGANTS. 114	114	ES TRES GERMANS I ES NOU GEGANTS.	139	152
EN PERE DE SA BUTZA 128	128	EN PERE DE SA BUTZA	153	157
ES SET CEROS 133	133	ES SET CEROS	158	170
ES SEGADOR I SA BEATA 146	146	ES SEGADOR I SA BEATA	171	174
EN SALOM I ES BAL'LE. 150	150	EN SALOM I ES BAL'LE.	175	189
N AGRACIAT 165	165	N AGRACIAT	190	198
ES CASTELL D'IRÁS I NO TORNARÁS 174	174	ES CASTELL D'IRÁS I NO TORNARÁS	199	237
Es QUATRE GERMANS 213	213	Es QUATRE GERMANS	238	252
S' HOMO I ES LLEÓ 228	228	S' HOMO I ES LLEÓ	253	255
N' ESPARDENYET 231	231	N' ESPARDENYET	256	268
Es DOs BESSONS 244	244	Es DOs BESSONS	269	280
SA RABOA I S' ERISSÓ 256	256	SA RABOA I S' ERISSÓ	281	293
SA RONDAIA D' EN VIT 269	269	SA RONDAIA D' EN VIT	294	297
BON-JESÚS I ETS ALTRES APÒSTOLS.. 273	273	BON-JESÚS I ETS ALTRES APÒSTOLS..	298	300

```

titulo=t2$titulo
length(titulo)

```

[1] 24

```

extrae <- function(i) {
  tomo1 %>%
    filter(pagina >= t2$indice[i] & pagina <= t2$final[i]) %>%
    pull(texto) %>%
    paste(collapse = "\n")}

sapply(1:length(titulo), extrae)-> rondallas
corpus1=tibble(titulo,rondallas)
corpus1

```

```

# A tibble: 24 x 2
  titulo                                rondallas
  <chr>                                <chr>
1 EN JUANET I ES SET MISSATGES        "EN JUANET I ES SET MISSATGES'\r\nee\r~
2 UN FESTETJADOR.                    "DIU I IME TE ES\r\nUN FESTETJADOR'\r~
3 S' HERMOSURA DEL MON               "EH\r\nS' HERMOSURA DEL MON\r\n--- Lee~
4 SA FIA DES CARBONERET               "P ecaomos ame dopoec entens mb\r\nSA ~
5 EN MARTÍ TACÓ .                    "Ei 8ede def dd ff dd def ed\r\nEN MAR~
6 ES CA D'EN BUA I ES MOIX D'EN PEJULÍ. "e\r\nES CA D'EN BUA I ES MOIX D'EN PE~
7 N'ESTEL D' OR                      "Ne er rer Gral,\r\n---é- en\r\nN' EST~
8 NA MAGRANETA.                      "l NA MAGRANETA:\r\n-----t I D- Ó\r\n~
9 SA JAIA XELOC I SA JAIA BIGALOT     "ISIRIRISISI DIT\r\nSA JAIA XELOC I SA~
10 EN JUANET DE SA GERRA              "e\r\nEN JUANET DE SA GERRA' l\r\n34IX~
# i 14 more rows

```

8.3 Tomo 2

Empezaremos por el tomo 1913, que es el que tiene un formato más parecido al tomo 1, con una tabla de contenidos al principio. El proceso de extracción del texto será similar al del tomo 1, utilizando la tabla de contenidos para identificar los límites de cada rondalla y luego extraer el texto correspondiente a cada una de ellas.

```

tomo2 <- read_csv("raw_text/rondalles_ocr_tomo2.csv")

```

```

Rows: 326 Columns: 3

```

```

-- Column specification -----

```

```

Delimiter: ","

```

```

chr (1): texto

```

```

dbl (1): pagina

```

```

lgl (1): error

```

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
n=dim(tomo2)[1]
n
```

```
[1] 326
```

```
# empieza la primera dondalla en la página 8
tomo2=tomo2[-c(1:7),]
tabla2 <- read_csv("raw_text/tabla_tomo2.csv")
```

```
Rows: 17 Columns: 2
```

```
-- Column specification -----
```

```
Delimiter: ","
```

```
chr (1): Título
```

```
dbl (1): Página
```

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
tabla2$final=c(tabla2$pagina[-1]-1,n)
```

Warning: Unknown or uninitialised column: `pagina`.

```
knitr::kable(tabla2)
```

Título	Página	final
GUARDAUVOS DE PEDRA REDONA, DE CAQUI NO LLADRA I D'HOMO ROIG	1	326
EN PERE DE SA COCA	49	326
ES PORT DE SA CIBOLLA BLANCA 39	59	326
EN PERE POCA POR.	77	326
ES SOLDADET DE SA MOTXILLA	97	326
LA POMARRINA	109	326
EN PERE TORT	117	326
SA FIA DEL SOL I DE LA LLUNA	140	326

Título	Página	final
L'AMO DESO-NA-MOIXA	166	326
LA PRINCESA BELLA	174	326
ES FII DES PESCADOR	198	326
LA FLOR ROMANIAL	229	326
EN GOSTÍ LLADRE	241	326
TRES GERMANS DESXONDITS	263	326
SA COMTESSA SENSE BRAÇOS	270	326
ES POAL FLORIT	284	326
ES REIM DEL REI-MORO AMB SET PAMS DE MORRO	288	326

```

titulo=tabla2$Título
titulo

```

```

[1] "GUARDAUVOS DE PEDRA REDONA, DE CAQUI NO LLADRA I D'HOMO ROIG"
[2] "EN PERE DE SA COCA"
[3] "ES PORT DE SA CIBOLLA BLANCA 39"
[4] "EN PERE POCA POR."
[5] "ES SOLDADET DE SA MOTXILLA"
[6] "LA POMARRINA"
[7] "EN PERE TORT"
[8] "SA FIA DEL SOL I DE LA LLUNA"
[9] "L'AMO DESO-NA-MOIXA"
[10] "LA PRINCESA BELLA"
[11] "ES FII DES PESCADOR"
[12] "LA FLOR ROMANIAL"
[13] "EN GOSTÍ LLADRE"
[14] "TRES GERMANS DESXONDITS"
[15] "SA COMTESSA SENSE BRAÇOS"
[16] "ES POAL FLORIT"
[17] "ES REIM DEL REI-MORO AMB SET PAMS DE MORRO"

```

Agrupemos cada rondalla en una entrada del corpus, utilizando la tabla de contenidos para identificar los límites de cada rondalla y luego extraer el texto correspondiente a cada una de ellas.

```

extrae <- function(i) {
  tomo2 %>%
    filter(pagina >= t2$indice[i] & pagina <= t2$final[i]) %>%
    pull(texto) %>%

```

```
paste(collapse = "\n")}

sapply(1:length(titulo), extrae)-> rondallas
corpus2=tibble(titulo,rondallas)
corpus2
```

```
# A tibble: 17 x 2
  titulo                                rondallas
  <chr>                                <chr>
1 GUARDAUVOS DE PEDRA REDONA, DE CAQUI NO LLADRA I D'HOMO ROIG "GUARDAU-
VOS DE~
2 EN PERE DE SA COCA                                "GUARDAUVOS DE ~
3 ES PORT DE SA CIBOLLA BLANCA 39                    "ç GUARDAU-
VOS ~
4 EN PERE POCA POR.                                "És EN PERE DE ~
5 ES SOLDADET DE SA MOTXILLA                        "62 RONDAIES MA~
6 LA POMARRINA                                       "00 ES PORT DE ~
7 EN PERE TORT                                       "EN PERE POCA P~
8 SA FIA DEL SOL I DE LA LLUNA                      "102 RONDAIES M~
9 L'AMO DESO-NA-MOIXA                              "L)\r\nCSORSCOR~
10 LA PRINCESA BELLA                                "EN PERE TORT 1~
11 ES FII DES PESCADOR                              "132 RONDAIES M~
12 LA FLOR ROMANIAL                                "146 RONDAIES M~
13 EN GOSTÍ LLADRE                                  "SA FIA DEL SOL~
14 TRES GERMANS DESXONDITS                          "164 RONDAIES M~
15 SA COMTESSA SENSE BRAÇOS                         "168 RONDAIES M~
16 ES POAL FLORIT                                    "LA PRINCESA BE~
17 ES REIM DEL REI-MORO AMB SET PAMS DE MORRO       "192 RONDAIES M~
```

Sería conveniente añadirle una columna indicando el número de aplec....:-)

8.4 Tomo 3

Cargo el tomo 3 y su tabla de contenidos

```
tomo3=read_csv("raw_text/rondalles_ocr_tomo3.csv")
```

Rows: 330 Columns: 3

-- Column specification -----

```
Delimiter: ","
chr (1): texto
dbl (1): pagina
lgl (1): error
```

```
i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
tabla3=read_csv("raw_text/tabla_tomo3.csv")
```

```
Rows: 19 Columns: 2
```

```
-- Column specification -----
```

```
Delimiter: ","
```

```
chr (1): titulo
```

```
dbl (1): pagina
```

```
i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
tabla3$indice=tabla3$pagina+10
n=dim(tomo3)[1]
n
```

```
[1] 330
```

```
tabla3$final=c(tabla3$indice[-1]-1,n)
```

Veamos el contenido de la tabla de contenidos

```
knitr::kable(tabla3)
```

titulo	pagina	indice	final
¿Val més matinetjar que a missa anar?	1	11	33
En Juanet de l' Onso	24	34	69
L' amor de les tres taronges	60	70	104
Es canyamet, s' aset i sa serra-porra	95	105	119
En Pere Grif	110	120	128
En Ferrandí	119	129	156
En Pere des forn	147	157	169

titulo	pagina	indice	final
S' estudiant de sa cova de Salamanca	160	170	186
En Pere de sa xua	177	187	200
En Juanet i es gigant	191	201	215
Es gallet, s' anyellet, sa godineta i es drac	206	216	228
Es lladre fadrí i es lladre casat	219	229	243
Es gorriónet	234	244	246
Sa cama-rotgera	237	247	263
Es fustet	254	264	288
Mestre Nadal de sa placeta del Socós	279	289	292
Amics de barret i amics vers	283	293	309
En Toni Garriguel · lok	300	310	318
Un pare i quatre fils	309	319	330

Ahora genero el corpus3

```
extrae <- function(i) {
  tomo3 %>%
    filter(pagina >= t2$indice[i] & pagina <= t2$final[i]) %>%
    pull(texto) %>%
    paste(collapse = "\n")}

corpus3 <- tibble(titulo=tabla3$titulo,rondallas=sapply(1:dim(tabla3)[1], extrae))
```

8.5 Tomo V

Lectura especial tomo V, que tiene un formato diferente al resto de tomos, ya que no tiene una tabla de contenidos al principio, sino que la tabla de contenidos se encuentra al final del tomo. Por ello, primero leeremos el texto completo del tomo y luego utilizaremos la tabla de contenidos para identificar los límites de cada rondalla y luego extraer el texto correspondiente a cada una de ellas.

Lectura tomo V y su tabla de contenidos

```
# tomo5=read_csv("raw_text/rondalles_ocr_tomo5.csv")
# tabla5=read_csv("raw_text/tabla_tomo5.csv")
```

8.6 Tomo VIII

Lectura especial tomo VIII, que tiene un formato diferente al resto de tomos, ya que no tiene una tabla de contenidos al principio, sino que la tabla de contenidos se encuentra al final del tomo. Por ello, primero leeremos el texto completo del tomo y luego utilizaremos la tabla de contenidos para identificar los límites de cada rondalla y luego extraer el texto correspondiente a cada una de ellas.

Lectura tomo VIII y su tabla de contenidos

La tabla de contenidos es

```
tomo8=read_csv("raw_text/tabla_tomo8.csv")
```

```
Rows: 4 Columns: 4
```

```
-- Column specification -----
```

```
Delimiter: ","
```

```
chr (1): titulo
```

```
dbl (3): pagina, indice, final
```

```
i Use `spec()` to retrieve the full column specification for this data.
```

```
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
n=dim(tomo8)[1]
```

```
titulo=c("Sa llampria Meravillosa",  
         "En' Pere Catorze",  
         "La Mare Baleueta",  
         "Es Mel.loro Rosso")
```

```
pagina=c(1, 54, 75,119)
```

```
indice=pagina+6
```

```
final=c(indice[-1]-1,n)
```

```
tibble(titulo,pagina,indice,final)
```

```
# A tibble: 4 x 4
```

	titulo	pagina	indice	final
	<chr>	<dbl>	<dbl>	<dbl>
1	Sa llampria Meravillosa	1	7	59
2	En' Pere Catorze	54	60	80
3	La Mare Baleueta	75	81	124
4	Es Mel.loro Rosso	119	125	4

```
#write_csv(tibble(titulo,pagina,indice,final),"raw_text/tabla_tomo8.csv")
```

Lectura del tomo VIII y su tabla de contenidos

```
tomo8=read_csv("raw_text/rondalles_ocr_tomo8.csv")
```

Rows: 175 Columns: 3

-- Column specification -----

Delimiter: ","

chr (1): texto

dbl (1): pagina

lgl (1): error

i Use `spec()` to retrieve the full column specification for this data.

i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
tabla8=read_csv("raw_text/tabla_tomo8.csv")
```

Rows: 4 Columns: 4

-- Column specification -----

Delimiter: ","

chr (1): titulo

dbl (3): pagina, indice, final

i Use `spec()` to retrieve the full column specification for this data.

i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
n=dim(tomo8)[1]
```

```
tabla8$final=c(tabla8$indice[-1]-1,n)
```

Veamos el contenido de la tabla de contenidos

```
knitr::kable(tabla8)
```

titulo	pagina	indice	final
Sa llampria Meravillosa	1	7	59
En' Pere Catorze	54	60	80
La Mare Baleueta	75	81	124

titulo	pagina	indice	final
Es Mel.loro Rosso	119	125	175

Ahora genero el corpus8

```
extrae <- function(i) {
  tomo8 %>%
    filter(pagina >= t2$indice[i] & pagina <= t2$final[i]) %>%
    pull(texto) %>%
    paste(collapse = "\n")}
corpus8 <- tibble(titulo=tabla8$titulo,rondallas=sapply(1:dim(tabla8)[1], extrae))
```

9 Referencias